Estadística descriptiva con R

Ejemplo de solución ejercicio práctico N°1

Enunciado

Sabemos que uno de los usos de los modelos estadísticos es describir o caracterizar un conjunto de datos, lo que aprendimos en la enseñanza secundaria y en cursos anteriores con el nombre de estadística descriptiva. Son muchas las herramientas, pero es importante saber usar la que es adecuada para lo que se quiere describir. Describir, sin embargo, no es el final del trabajo: un gráfico o un estadístico no dicen por sí solos qué responder.

En este contexto trabajaremos con una selección de datos públicos recopilados por la encuesta Casen 2024 en la Región Metropolitana (RM). Cada fila es un hogar, descrito a través de la persona reconocida como jefa o jefe de hogar. La siguiente tabla detalla las columnas seleccionadas:

Descripción de los datos

Columna	Descripción
folio	Identificador del hogar
provincia	Provincia de la Región Metropolitana: Chacabuco, Cordillera, Maipo, Melipilla, Santiago o Talagante
comuna	Comuna donde vive el hogar (52 comunas)
area	Zona donde está la vivienda: Urbano o Rural
edad	Edad, en años, de la jefatura de hogar
sexo	Sexo de la jefatura de hogar: Hombre o Mujer
ecivil	Estado conyugal de la jefatura de hogar (8 categorías, de Casado(a) a Soltero(a))
nivel_educ	Nivel educacional más alto al que asistió la jefatura de hogar (14 categorías, de “Nunca asistió” a “Doctorado”)
h_trab_sem	Horas que la jefatura de hogar trabaja habitualmente por semana en su trabajo principal
tipo_trab	Tipo del trabajo principal de la jefatura de hogar: permanente, de temporada, ocasional, a prueba o por plazo determinado

Columna	Descripción
ing_aut_hogar	**Ingresos autónomos totales del hogar, en pesos: lo que el hogar genera por su cuenta —trabajo, pensiones, arriendos y rentas—, sin los subsidios del Estado**
num_pers_hogar	**Cantidad de personas que viven habitualmente en la vivienda**

Cada equipo debe responder la pregunta que le fue asignada: elegir las variables, comprometerse de antemano con una medida y un gráfico, producirlos con R y responder en cinco a diez líneas, diciendo en qué se apoya la respuesta y qué no se puede concluir con estos datos.

Este ejemplo sigue esos mismos pasos con **seis preguntas distintas de las asignadas a los equipos**, una por cada tipo de análisis que suele aparecer en estadística descriptiva. En cada una partimos por identificar las variables que importan y su tipo. Luego, antes de mirar resultados, nos comprometemos con una medida y un gráfico, y con lo que esperaríamos ver si la respuesta fuera que sí y si fuera que no. Recién entonces calculamos y graficamos, respondemos apoyándonos en un valor o en un rasgo del gráfico, y terminamos diciendo qué no se puede concluir con estos datos.

Preparación de los datos

Comencemos incluyendo los paquetes que usaremos en este script.

```
library(dplyr)
library(ggpubr)
```

A continuación obtengamos los datos. El archivo usa coma como separador y punto decimal, así que se lee con `read.csv()`; con `read.csv2()`, que espera punto y coma, quedaría todo en una sola columna.

```
src_dir <- "~/Downloads"
src_basename <- "EP01-Datos-Casen2024-RM.csv"
src_file <- file.path(src_dir, src_basename)

datos <- read.csv(src_file, stringsAsFactors = TRUE)
str(datos)
```

```
'data.frame':   14151 obs. of  12 variables:
 $ folio         : int  100020301 100020401 100020501 100020801 100160301 100160401 1001
60501 100160601 100160701 100160801 ...
 $ provincia     : Factor w/ 6 levels "Chacabuco","Cordillera",..: 5 5 5 5 5 5 5 5 5 5
...
 $ comuna        : Factor w/ 52 levels "Alhué","Buin",..: 41 41 41 41 5 5 5 5 5 5 ...
 $ area          : Factor w/ 2 levels "Rural","Urbano": 2 2 2 2 2 2 2 2 2 2 ...
 $ edad          : int  62 61 55 54 63 92 38 83 59 72 ...
 $ sexo          : Factor w/ 2 levels "Hombre","Mujer": 1 1 1 2 2 2 2 1 1 1 ...
 $ ecivil        : Factor w/ 8 levels "1. Casado(a)",..: 8 1 1 1 2 7 2 1 2 1 ...
 $ nivel_educ    : Factor w/ 14 levels "1. Nunca asistió",..: 14 12 5 14 14 12 12 11 14
12 ...
 $ h_trab_sem    : int  NA 40 40 NA NA NA NA NA 44 44 ...
 $ tipo_trab     : Factor w/ 7 levels "1. Permanente",..: NA 1 1 NA NA NA NA NA 1 1 ...
 $ ing_aut_hogar : num  186000 3253500 500000 780000 800000 ...
 $ num_pers_hogar: int  2 4 1 5 5 8 7 2 2 2 ...
```

Revisemos los tipos. Las columnas de texto quedaron como factores y las numéricas como enteros o reales, que es lo que corresponde, con una excepción: `folio` es un **identificador**, no una cantidad. Promediar folios no tiene sentido, así que lo dejamos como texto.

```
datos[["folio"]] <- as.character(datos[["folio"]])
```

Notemos también que los niveles de `ecivil`, `nivel_educ` y `tipo_trab` traen un número adelante ("1. Casado(a)"). Ese número es el código de la encuesta y hace que R ordene los niveles según el código y no alfabéticamente, pero **no siempre es un orden con sentido**: hay que mirarlo antes de usarlo.

> ⚠️ **Antes de resumir, hay que mirar.** Estos datos son de una encuesta real. Por eso, en cada pregunta revisamos primero cuántos casos hay en cada grupo y si hay valores faltantes en las variables que usamos.

Una variable categórica

> **¿Cuál es la situación conyugal más frecuente entre las jefaturas de hogar de la RM?**

En este caso, solo hay una variable relevante: `ecivil`, que es categórica nominal, con 8 niveles.

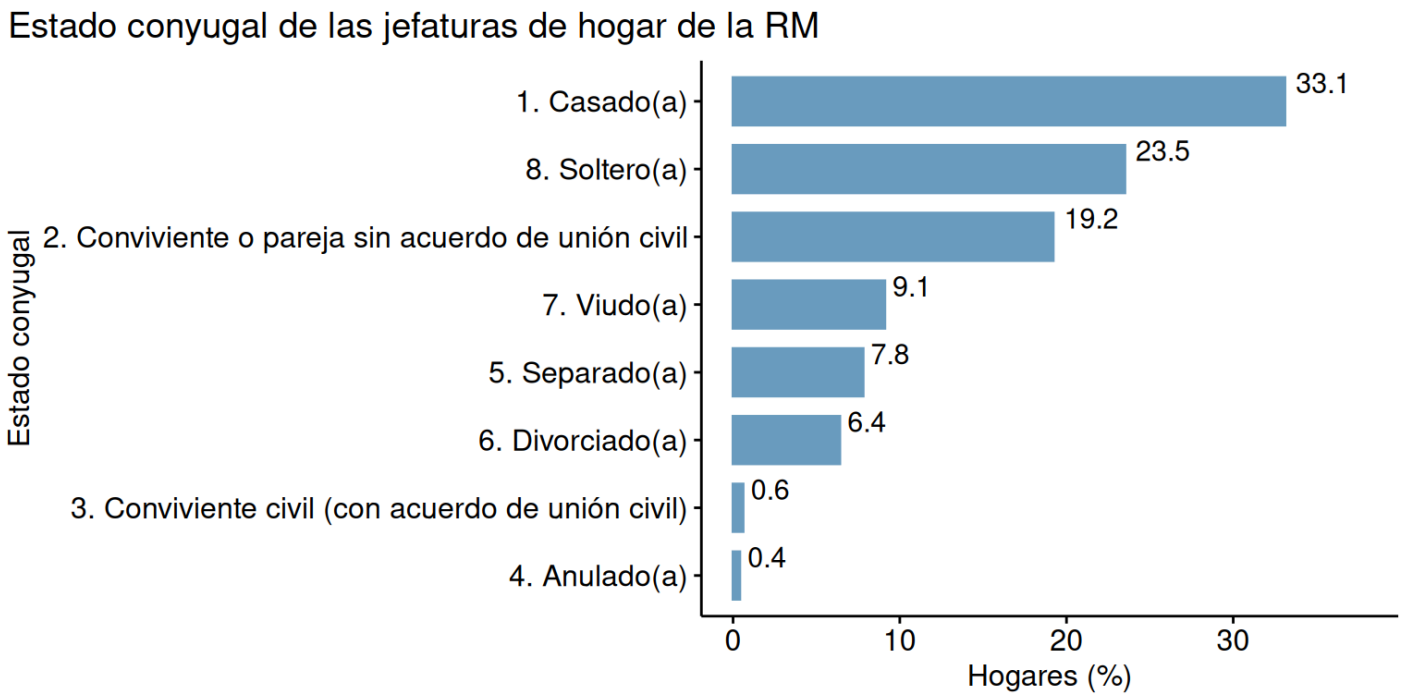
Para una variable categórica, la medida adecuada es la **frecuencia**, y para compararlas conviene la **proporción**: cuántos hogares hay en cada categoría respecto del total. Como gráfico usaremos uno de **barras**, que se lee mejor que una torta cuando lo que interesa es **comparar**. Si hay una situación claramente más frecuente, veremos una barra bastante más alta que las demás; si no la hay, barras de altura parecida.

```
# Frecuencia y proporción de cada estado conyugal, de la más a la menos frecuente
tabla_ecivil <- datos |>
  count(ecivil, name = "frecuencia") |>
  mutate(proporcion = round(frecuencia / sum(frecuencia) * 100, 1)) |>
  arrange(desc(frecuencia))

print(tabla_ecivil)
```

```
                                          ecivil frecuencia proporcion
1                                  1. Casado(a)       4683       33.1
2                                 8. Soltero(a)       3322       23.5
3 2. Conviviente o pareja sin acuerdo de unión civil       2711       19.2
4                                   7. Viudo(a)       1282        9.1
5                                5. Separado(a)       1110        7.8
6                              6. Divorciado(a)        900        6.4
7  3. Conviviente civil (con acuerdo de unión civil)         87        0.6
8                                  4. Anulado(a)         56        0.4
```

```
# Barras horizontales, para que se lean los nombres largos, de la más a la
# menos frecuente, con la proporción como rótulo.
tabla_ecivil[["ecivil"]] <- factor(tabla_ecivil[["ecivil"]],
                                   levels = rev(tabla_ecivil[["ecivil"]]))
g_ecivil <- ggbarplot(tabla_ecivil, x = "ecivil", y = "proporcion",
                      fill = "#6D9EC1", color = "#6D9EC1",
                      label = TRUE, lab.pos = "out", lab.hjust = -0.2, orientation = "ho
riz",
                      title = "Estado conyugal de las jefaturas de hogar de la RM",
                      xlab = "Estado conyugal", ylab = "Hogares (%)")
g_ecivil <- g_ecivil + scale_y_continuous(limits = c(0, 38))
g_ecivil <- g_ecivil + theme(plot.title.position = "plot")
print(g_ecivil)
```



El gráfico muestra una barra más alta que las demás, la de las personas casadas, pero no por mucho: le siguen solteras y convivientes. Hay además dos categorías muy pequeñas, con 87 y 56 hogares.

La respuesta cambia si agrupamos. Las categorías 1, 2 y 3 del código —casado, conviviente civil y conviviente sin acuerdo— describen a personas **en pareja**. Juntas son el 52,9 % de las jefaturas de hogar.

La situación conyugal más frecuente entre las jefaturas de hogar de la RM es la de **casado(a)**, con el 33,1 % de los hogares, seguida de soltero(a) con el 23,5 %. Pero ninguna categoría reúne a la mayoría: casado(a) es la barra más alta del gráfico por un margen moderado. Si la pregunta es si la jefatura de hogar vive **en pareja**, sumando matrimonio y convivencia, la respuesta es que sí en la mayoría de los casos: el 52,9 %.

Debemos tener cuidado, eso sí, con el alcance de esta respuesta. Estos datos describen a las **jefaturas de hogar**, no a toda la población adulta: no permiten decir cuántas personas de la RM están casadas.

Una variable numérica

¿De cuántas personas es un hogar típico de la RM?

Nuevamente hay una sola variable relevante, `num_pers_hogar`, que es numérica **discreta**: cuenta personas, así que solo toma valores enteros.

Para describir un valor típico usaremos la **media**, la **mediana** y la **moda**, con los **cuartiles** para ver la dispersión. Si la distribución es simétrica, las tres medidas estarán cerca y cualquiera sirve; si tiene una cola hacia los hogares grandes, la media quedará por encima de la mediana y conviene informar la mediana. Como la variable es discreta, en vez de un histograma usaremos un gráfico de **barras con una barra por cada tamaño de hogar**: un histograma juntaría tamaños distintos en un mismo intervalo.

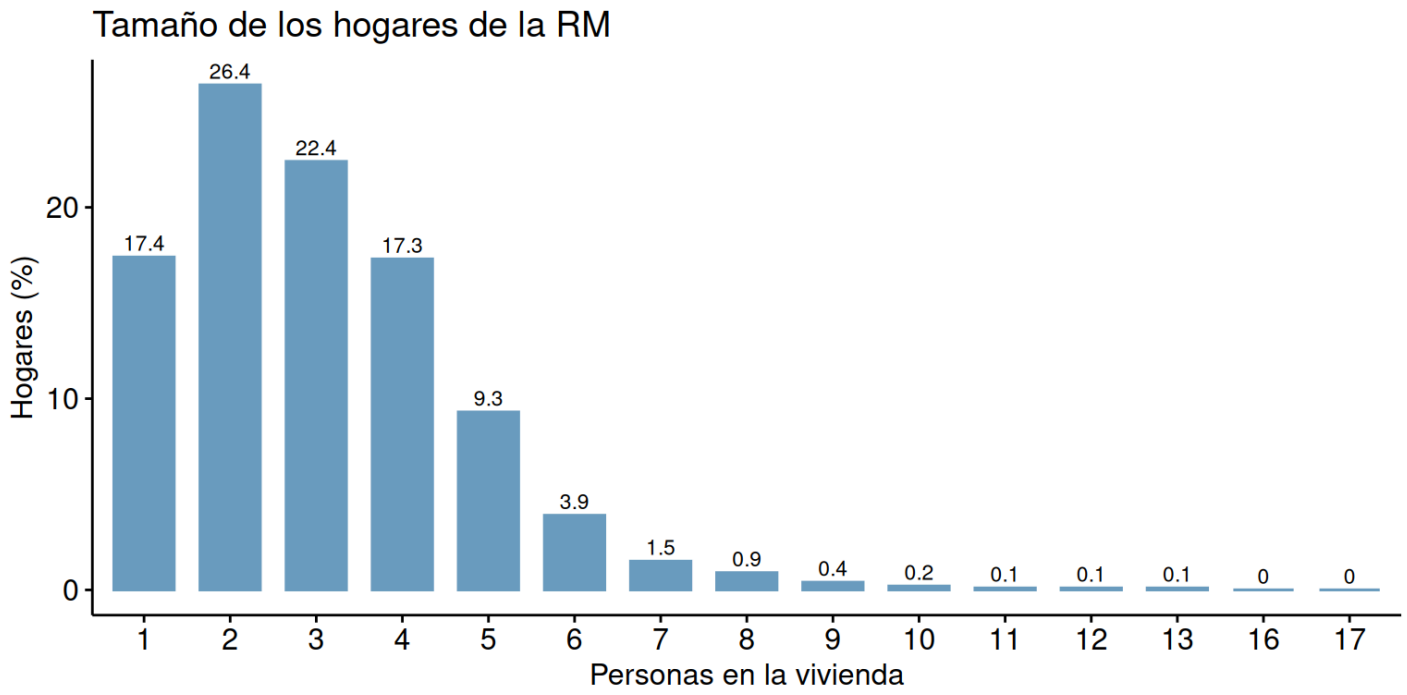
```
# Medidas de posición y de dispersión del tamaño del hogar
tamano <- datos[["num_pers_hogar"]]
frec_tamano <- table(tamano)

cat("Casos sin dato:", sum(is.na(tamano)), "\n")
cat("Media:  ", round(mean(tamano), 2), "\n")
cat("Moda:   ", names(frec_tamano)[which.max(frec_tamano)], "\n")
print(quantile(tamano, c(0, 0.25, 0.5, 0.75, 1)))
```

```
Casos sin dato: 0
Media:   3.04
Moda:    2
  0%  25%  50%  75% 100%
   1    2    3    4   17
```

```
# Una barra por tamaño de hogar, en proporción del total
tabla_tamano <- as.data.frame(frec_tamano)
colnames(tabla_tamano) <- c("personas", "frecuencia")
tabla_tamano[["proporcion"]] <- round(tabla_tamano[["frecuencia"]] / length(tamano) * 10
0, 1)

g_tamano <- ggbarplot(tabla_tamano, x = "personas", y = "proporcion",
                      fill = "#6D9EC1", color = "#6D9EC1",
                      label = TRUE, lab.pos = "out", lab.size = 3,
                      title = "Tamaño de los hogares de la RM",
                      xlab = "Personas en la vivienda", ylab = "Hogares (%)")
print(g_tamano)
```



El gráfico muestra una distribución **asimétrica hacia la derecha**: la mayoría de los hogares tiene entre una y cuatro personas y hay una cola larga de hogares grandes, que llega hasta 17 personas. Aun así, la cola es delgada y la media (3,04) casi no se aparta de la mediana (3).

Podemos concluir que un hogar típico de la RM es de **dos o tres personas**. El tamaño más frecuente es 2 (la moda, con el 26,4 % de los hogares) y la mitad de los hogares tiene 3 personas o menos (la mediana). La mitad central de los hogares tiene entre 2 y 4 personas, y el 83,5 % tiene cuatro o menos. Los hogares de una sola persona no son raros: son el 17,4 %. La cola de hogares grandes existe, pero es tan delgada que la media, 3,04, queda muy cerca de la mediana.

Hay, sin embargo, un límite que conviene señalar. La variable cuenta a las personas que viven **en la vivienda**, y en una vivienda puede haber más de un hogar: para esos casos, el tamaño del hogar queda sobrestimado, y estos datos no permiten saber cuántos son.

Una variable numérica en dos grupos

¿Son mayores las jefaturas de hogar rurales que las urbanas?

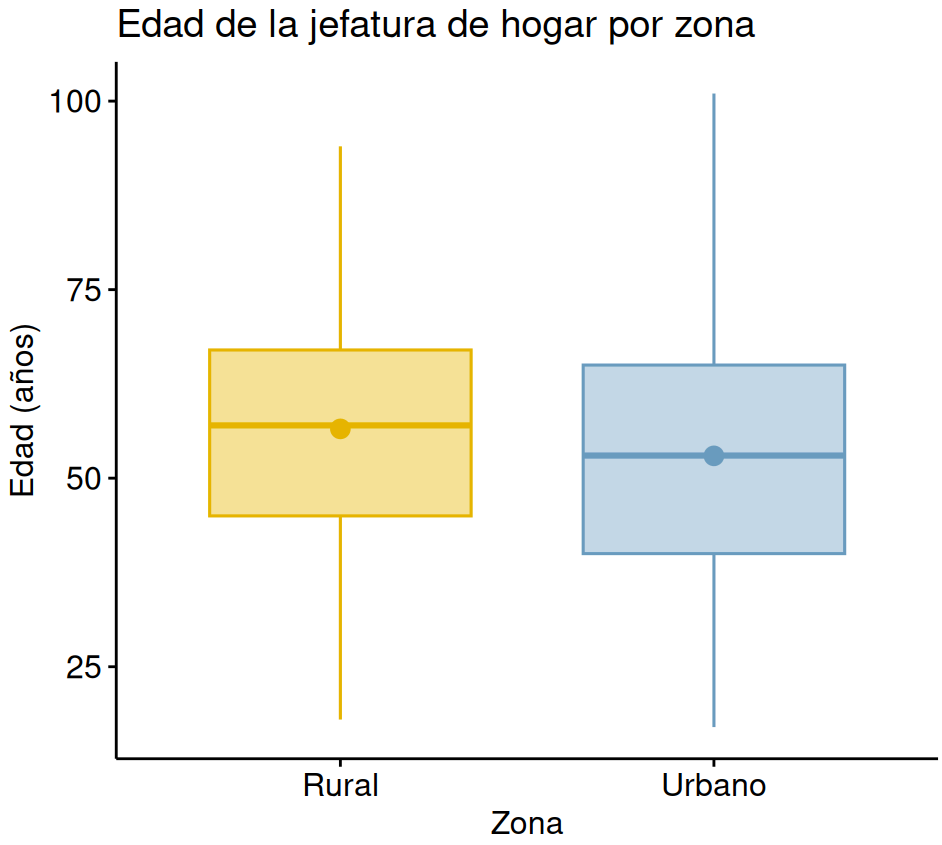
Aquí necesitamos dos variables: `edad`, que es numérica, y `area`, categórica con dos niveles, que define los grupos que queremos comparar.

Compararemos la **mediana** y el **rango intercuartil** de la edad en cada zona, junto con el número de casos de cada grupo. Como gráfico usaremos un **diagrama de cajas** por zona, que pone lado a lado dónde está el centro y cuánto se dispersa cada grupo. Si hay alguna diferencia de edad entre las zonas, veremos las cajas a distinta altura; si no la hay, a la misma altura.

```
# Tamaño, centro y dispersión de la edad en cada zona
edad_area <- datos |>
  group_by(area) |>
  summarise(n = n(),
            media = round(mean(edad), 1),
            mediana = median(edad),
            Q1 = quantile(edad, 0.25),
            Q3 = quantile(edad, 0.75),
            IQR = IQR(edad))
print(edad_area)
```

```
# A tibble: 2 × 7
  area       n media mediana    Q1    Q3   IQR
  <fct>  <int> <dbl>   <dbl> <dbl> <dbl> <dbl>
1 Rural    836  56.5      57    45    67    22
2 Urbano 13315  53        53    40    65    25
```

```
# Cajas por zona, con la media marcada
g_area <- ggboxplot(datos, x = "area", y = "edad",
                    color = "area", fill = "area", palette = c("#E7B800", "#6D9EC1"),
                    alpha = 0.4, add = "mean",
                    title = "Edad de la jefatura de hogar por zona",
                    xlab = "Zona", ylab = "Edad (años)")
g_area <- g_area + rremove("legend")
print(g_area)
```



La caja rural aparece algo más arriba que la urbana, pero las dos se superponen casi por completo. Y los grupos son de tamaños muy distintos: 836 hogares rurales contra 13.315 urbanos. El rural es solo el 5,9 % de los datos.

Podemos responder que sí: en estos datos las jefaturas de hogar rurales son **algo mayores** que las urbanas: la mediana de edad es de 57 años en la zona rural y de 53 en la urbana, una diferencia de 4 años, y los dos cuartiles también son mayores en lo rural (45–67 contra 40–65). La diferencia es pequeña comparada con la dispersión dentro de cada zona: el rango intercuartil es de más de 20 años en las dos, y las cajas del gráfico se superponen casi enteras.

Pero con solo 836 hogares rurales, esta diferencia de 4 años podría ser distinta en otra muestra. Los datos tampoco dicen **por qué** hay diferencia —por ejemplo, si los jóvenes rurales se van a la ciudad—.

Una variable numérica en más de dos grupos

¿Cambia la edad de la jefatura de hogar según su estado conyugal?

Las variables son otra vez `edad`, numérica, y ahora `ecivil`, categórica con 8 niveles, que define los grupos.

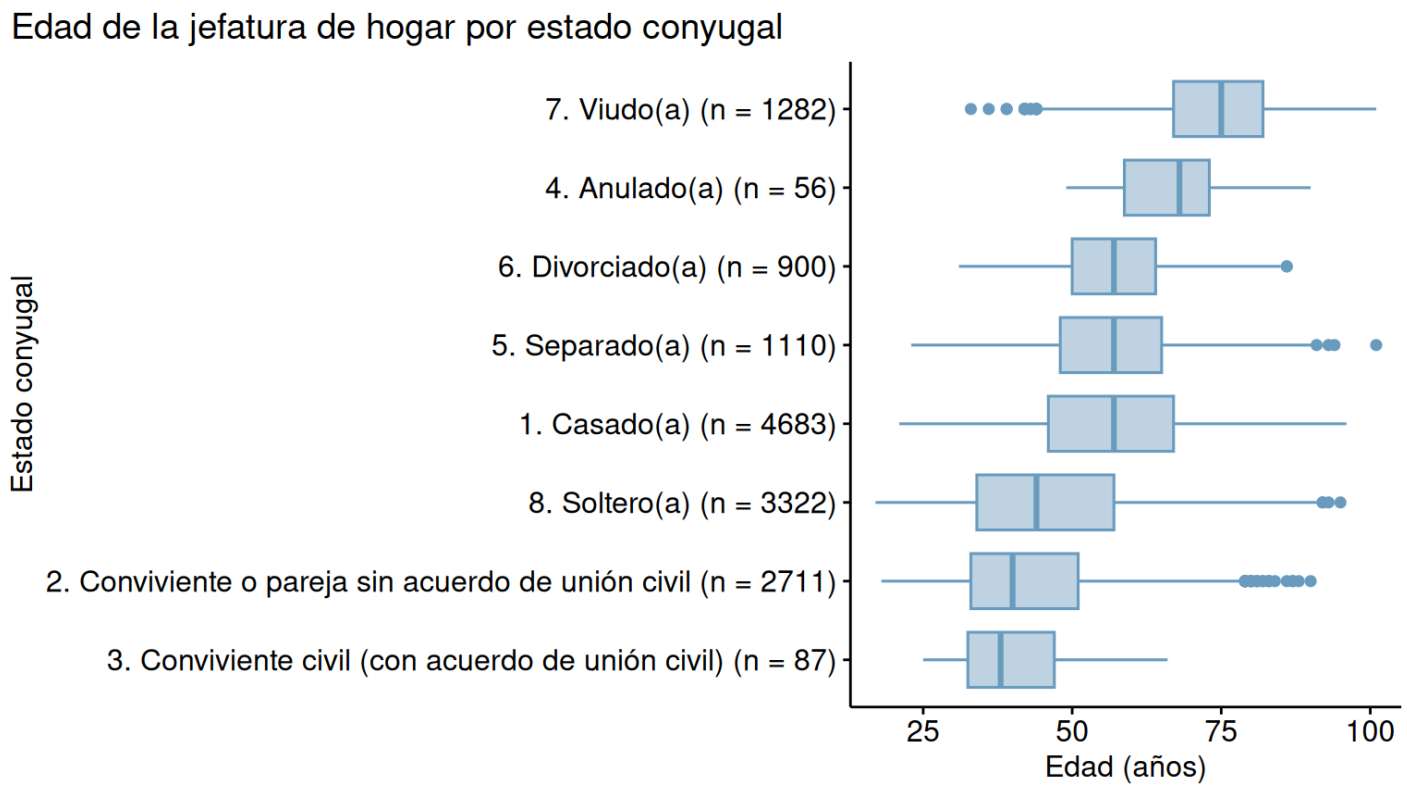
Como en la pregunta anterior, usaremos la **mediana**, los **cuartiles** y el **número de casos** de cada grupo, y un **diagrama de cajas** por estado conyugal. Con ocho grupos conviene ordenarlos por su mediana, para que el gráfico se lea de un vistazo. Si la edad cambia con el estado conyugal, veremos cajas a distintas alturas; si no, todas a una misma altura.

```
# Centro y dispersión de la edad por estado conyugal, ordenados por la mediana
edad_ecivil <- datos |>
  group_by(ecivil) |>
  summarise(n = n(),
            mediana = median(edad),
            Q1 = quantile(edad, 0.25),
            Q3 = quantile(edad, 0.75)) |>
  arrange(mediana)
print(edad_ecivil)
```

```
# A tibble: 8 × 5
  ecivil                                                n mediana    Q1    Q3
  <fct>                                             <int>   <dbl> <dbl> <dbl>
1 3. Conviviente civil (con acuerdo de unión civil)    87      38  32.5    47
2 2. Conviviente o pareja sin acuerdo de unión civil  2711      40  33      51
3 8. Soltero(a)                                       3322      44  34      57
4 1. Casado(a)                                        4683      57  46      67
5 5. Separado(a)                                      1110      57  48      65
6 6. Divorciado(a)                                     900      57  50      64
7 4. Anulado(a)                                         56      68  58.8    73
8 7. Viudo(a)                                         1282      75  67      82
```

```
# Cajas horizontales ordenadas por mediana; las etiquetas del eje dicen cuántos
# casos tiene cada grupo.
datos_ecivil <- datos |>
  mutate(ecivil = reorder(ecivil, edad, FUN = median))
rotulos <- setNames(paste0(edad_ecivil[["ecivil"]], " (n = ", edad_ecivil[["n"]], ")"),
                    edad_ecivil[["ecivil"]])

g_ecivil_edad <- ggboxplot(datos_ecivil, x = "ecivil", y = "edad",
                           fill = "#BFD5E3", color = "#6D9EC1", orientation = "horizonta
l",
                           title = "Edad de la jefatura de hogar por estado conyugal",
                           xlab = "Estado conyugal", ylab = "Edad (años)")
g_ecivil_edad <- g_ecivil_edad + scale_x_discrete(labels = rotulos)
g_ecivil_edad <- g_ecivil_edad + theme(plot.title.position = "plot")
print(g_ecivil_edad)
```



Las cajas quedan a alturas muy distintas, y el salto entre los extremos es grande. Dos grupos, eso sí, tienen muy pocos casos: anulado(a) y conviviente civil, con 56 y 87 hogares.

Concluimos que sí: la edad de la jefatura de hogar cambia mucho según su estado conyugal. Las personas que conviven son las más jóvenes (mediana de 40 años sin acuerdo de unión civil) y les siguen las solteras (44). Las casadas, separadas y divorciadas están en torno a los 57, y las viudas son claramente las mayores, con una mediana de 75 años y una caja que casi no se superpone con la de quienes conviven.

Esto no significa, sin embargo, que la edad determine el estado conyugal, ni al revés: las personas que hoy tienen 75 años se casaron en una época en que convivir era poco frecuente, y el acuerdo de unión civil existe recién desde 2015, lo que explica que sus casos sean jóvenes. Para anulado(a) y conviviente civil, con menos de 100 casos cada uno, las medianas son poco confiables.

Dos variables numéricas

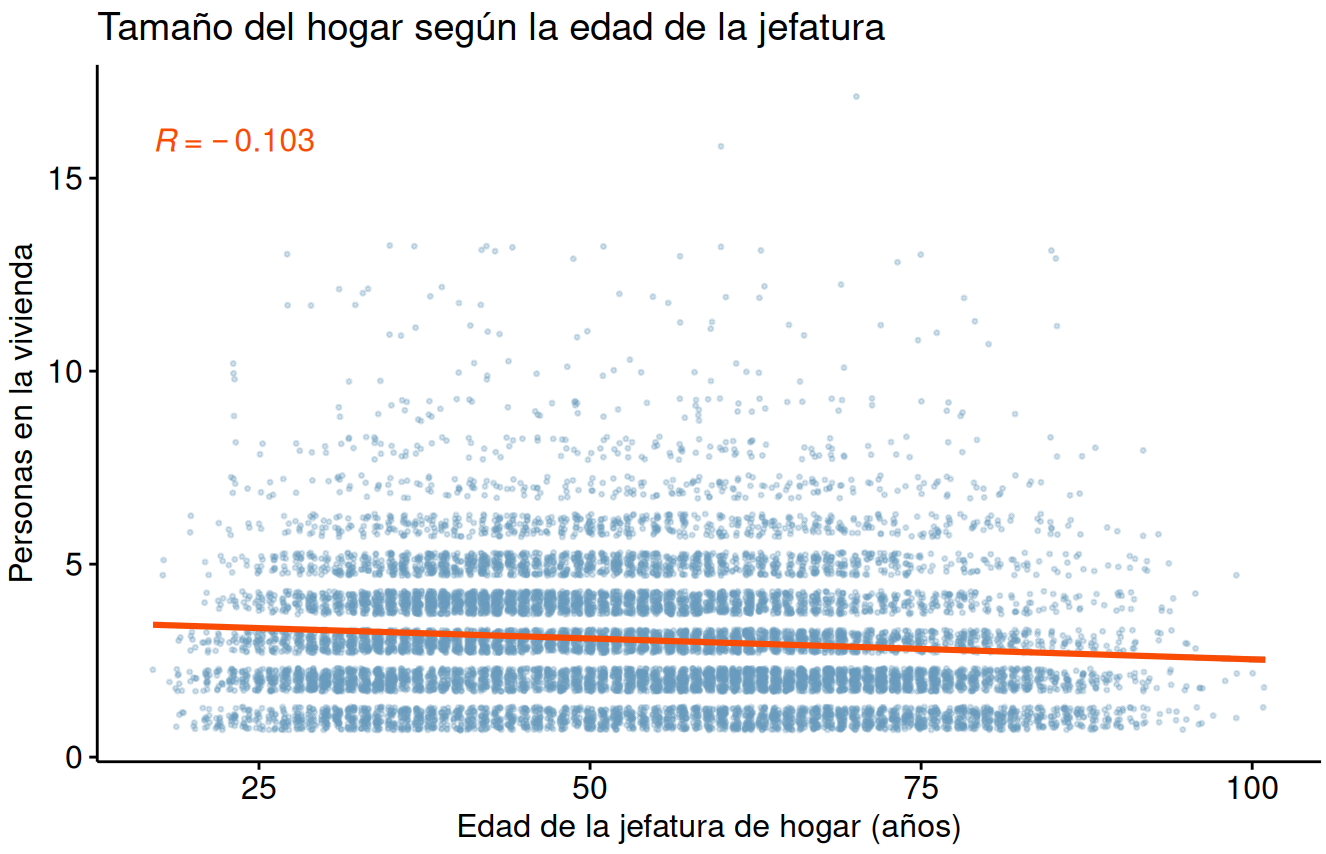
¿Tienen hogares más grandes las jefaturas de hogar de más edad?

En este caso las variables relevantes son `edad` y `num_pers_hogar`, las dos numéricas.

Para estudiar la relación entre dos variables numéricas, la herramienta natural es un **gráfico de dispersión**, acompañado del coeficiente de correlación de **Pearson** y de una **recta de regresión**, como vimos en el curso anterior. Si los hogares crecen con la edad, veremos una nube que sube hacia la derecha, una recta con pendiente positiva y un coeficiente positivo; si no, una nube horizontal, una recta plana y un coeficiente cercano a cero.

Como el tamaño del hogar solo toma valores enteros, los puntos quedarían apilados en líneas horizontales y taparían unos a otros. Los separamos un poco al azar (*jitter*) solo para dibujarlos.

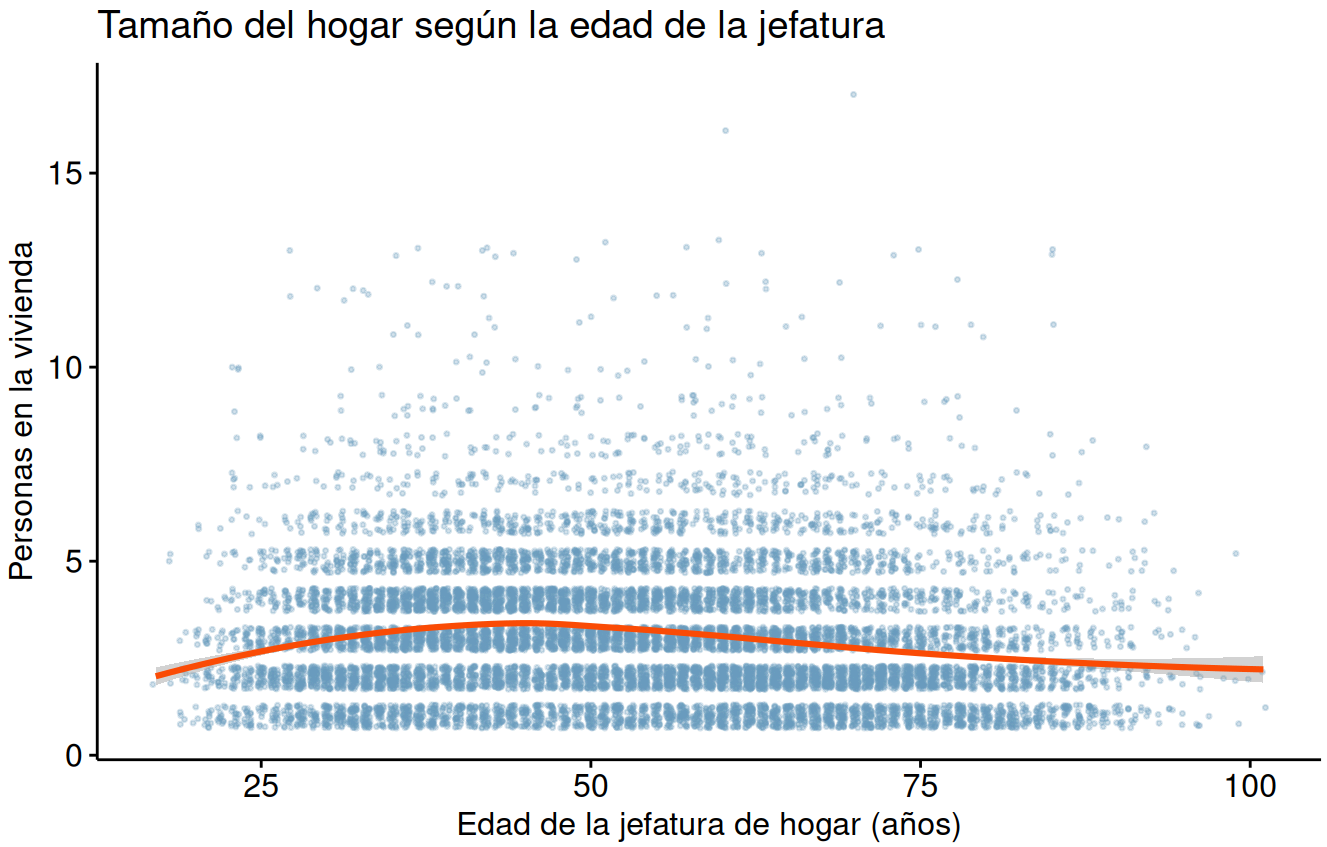
```
# Dispersión con jitter, recta de regresión y coeficiente de Pearson
set.seed(2024)
g_disp <- ggscatter(datos, x = "edad", y = "num_pers_hogar",
                    color = "#6D9EC1", size = 0.5, alpha = 0.3,
                    position = position_jitter(width = 0.3, height = 0.3),
                    title = "Tamaño del hogar según la edad de la jefatura",
                    xlab = "Edad de la jefatura de hogar (años)",
                    ylab = "Personas en la vivienda")
g_recta <- g_disp + stat_smooth(method = "lm", formula = y ~ x, color = "#FC4E07")
g_recta <- g_recta + stat_cor(aes(label = after_stat(r.label)), method = "pearson",
                              color = "#FC4E07", r.accuracy = 0.001, label.y = 16)
print(g_recta)
```



La recta es casi plana, apenas descendente, y el coeficiente es negativo y muy débil (R = −0,103). Con esto diríamos que el tamaño del hogar casi no tiene relación con la edad de la jefatura.

Pero antes de concluir conviene preguntarse si una recta describe bien esta nube. Agreguemos una curva suavizada, que sigue la tendencia de los datos sin forzarla a ser una recta, y calculemos el tamaño medio del hogar por tramo de edad.

```
# La misma nube, ahora con una curva suavizada (loess) en vez de la recta
g_curva <- g_disp + geom_smooth(method = "loess", formula = y ~ x, color = "#FC4E07")
print(g_curva)
```




```
# Tamaño medio del hogar por tramo de edad
tramos <- c(0, 29, 39, 49, 59, 69, 79, Inf)
nombres_tramos <- c("hasta 29", "30-39", "40-49", "50-59", "60-69", "70-79", "80 o más")
tamano_por_edad <- datos |>
  mutate(tramo = cut(edad, tramos, labels = nombres_tramos)) |>
  group_by(tramo) |>
  summarise(n = n(), media = round(mean(num_pers_hogar), 2))
print(tamano_por_edad)
```

```
# A tibble: 7 × 3
  tramo        n media
  <fct>    <int> <dbl>
1 hasta 29   893  2.79
2 30-39     2517  3.14
3 40-49     2724  3.4
4 50-59     2825  3.2
5 60-69     2705  2.94
6 70-79     1673  2.6
7 80 o más   814  2.41
```

La curva no es plana: **sube y después baja**. La tabla por tramo lo confirma: el tamaño medio del hogar crece hasta el tramo de 40-49 años (3,40 personas) y de ahí en adelante disminuye. Tenemos que retroceder: la recta no era una buena descripción de estos datos, y el coeficiente tampoco.

⚠️ **Un coeficiente de correlación resume solo la tendencia a subir o a bajar.** El coeficiente de Pearson mide cuánto se parece la relación a una recta. Cuando la relación sube y después baja, las dos mitades se compensan y el coeficiente queda cerca de cero aunque la relación exista. Por eso **el gráfico no es un adorno**: es el que muestra que el coeficiente no alcanza.

Concluimos que no: los hogares no son más grandes mientras mayor es la jefatura de hogar, pero eso no quiere decir que no haya relación. La relación tiene forma de **arco**: el tamaño medio del hogar crece desde 2,79 personas en las jefaturas de hasta 29 años hasta 3,40 entre los 40-49 años, y baja a 2,41 en las de 80 o más. La recta de regresión y el coeficiente de Pearson (R = −0,103) no lo muestran porque la subida y la bajada se compensan; lo que muestra el arco es la curva suavizada del gráfico.

Debemos notar, eso sí, que los datos son de un solo momento: comparan a personas distintas de distintas edades, no a un mismo hogar a lo largo del tiempo. El arco es compatible con la idea de que los hogares crecen con los hijos y se achican cuando se van, pero estos datos no permiten afirmarlo.

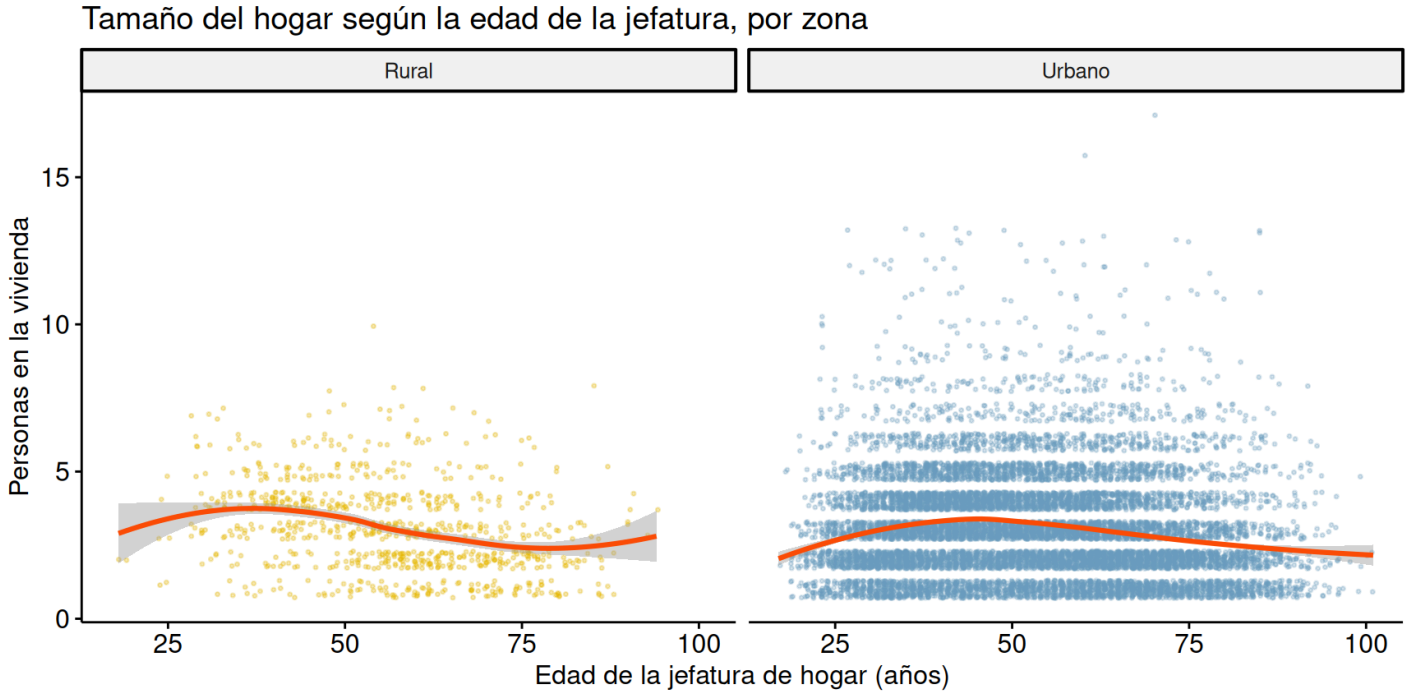
Dos variables numéricas en grupos distintos

¿Es igual esa relación entre la edad de la jefatura y el tamaño del hogar en las zonas urbanas y en las rurales?

Usamos las mismas dos variables numéricas, `edad` y `num_pers_hogar`, y agregamos `area`, categórica, para separar los grupos.

Repetiremos el análisis de la pregunta anterior, pero **separado por zona**: un gráfico de dispersión para cada una y la tabla del tamaño medio por tramo de edad. Si la relación es igual, veremos dos curvas con la misma forma; si no, curvas distintas.

```
# El mismo gráfico, un panel por zona
set.seed(2024)
g_disp_area <- ggscatter(datos, x = "edad", y = "num_pers_hogar",
                         color = "area", palette = c("#E7B800", "#6D9EC1"),
                         size = 0.5, alpha = 0.3,
                         position = position_jitter(width = 0.3, height = 0.3),
                         title = "Tamaño del hogar según la edad de la jefatura, por zon
a",
                         xlab = "Edad de la jefatura de hogar (años)",
                         ylab = "Personas en la vivienda")
g_disp_area <- g_disp_area + geom_smooth(method = "loess", formula = y ~ x, color = "#FC
4E07")
g_disp_area <- g_disp_area + facet_wrap(~ area) + rremove("legend")
print(g_disp_area)
```




```
# Tamaño medio del hogar por tramo de edad, en cada zona
tamano_area <- datos |>
  mutate(tramo = cut(edad, tramos, labels = nombres_tramos)) |>
  group_by(area, tramo) |>
  summarise(n = n(), media = round(mean(num_pers_hogar), 2), .groups = "drop")
print(tamano_area, n = Inf)
```

```
# A tibble: 14 × 4
   area   tramo        n media
   <fct>  <fct>    <int> <dbl>
 1 Rural  hasta 29    17  3.76
 2 Rural  30-39       96  3.72
 3 Rural  40-49      159  3.66
 4 Rural  50-59      211  3.11
 5 Rural  60-69      179  2.78
 6 Rural  70-79      126  2.38
 7 Rural  80 o más    48  2.4
 8 Urbano hasta 29   876  2.77
 9 Urbano 30-39     2421  3.12
10 Urbano 40-49     2565  3.39
11 Urbano 50-59     2614  3.21
12 Urbano 60-69     2526  2.96
13 Urbano 70-79     1547  2.62
14 Urbano 80 o más   766  2.41
```

Las dos curvas tienen una forma parecida y terminan en el mismo lugar, pero en lo rural el máximo llega antes. En la zona urbana se repite el arco de la pregunta anterior, con el máximo en el tramo de 40-49 años; en la rural, los hogares con jefaturas de 30-39 años ya son los más grandes. La curva rural también sube al comienzo, pero en ese tramo hay muy pocos puntos, y la banda gris que la rodea se ensancha justamente ahí.

En lo grueso, la relación es parecida en las dos zonas: el tamaño del hogar es mayor en la edad media y disminuye con los años, hasta coincidir en las jefaturas de 80 años o más (2,40 y 2,41). La diferencia está en las jefaturas jóvenes: entre los 30 y 39 años, los hogares rurales tienen en promedio 3,72 personas y los urbanos 3,12, y en lo rural el máximo llega antes.

Pero en lo rural hay solo 17 hogares con jefaturas de menos de 30 años y 96 entre 30 y 39, así que no sabemos si esa diferencia se mantendría con más datos. Y, como antes, los datos no dicen por qué: si en el campo los jóvenes viven con otros familiares, tienen hijos antes o es otra cosa.