Inferencia con una y dos muestras

Ejemplo de solución ejercicio práctico N°2

Enunciado

Los intervalos de confianza y la forma de la distribución muestral de los estadísticos más simples, como las medias y las proporciones, nos permiten poner a prueba hipótesis sobre el valor de un parámetro en la población. Esto lo hicimos en el curso anterior, y aquí queremos recordarlo y aclarar los procedimientos y las herramientas de R para realizarlos.

El archivo `EP02-Datos.csv` trae los datos de un programa piloto de desarrollo de talentos en atletismo, que eligió al azar a 101 de los varios miles de varones de 15 a 17 años que corrieron los 100 metros planos en los juegos escolares del año, y los entrenó durante seis meses en centros de tres zonas del país. Cada fila es un atleta. La siguiente tabla detalla sus columnas:

Descripción de los datos

Columna	Descripción
Id	Identificador del atleta
Zona	Zona del centro donde entrenó: Centro-Norte, Centro-Sur o Sur
Previo	Mejor marca del atleta en los 100 metros planos antes de entrar al programa, en segundos
Posterior	Mejor marca del atleta en los 100 metros planos tras los seis meses de entrenamiento, en segundos

Cada equipo debe analizar las cuatro preguntas que le fueron asignadas, proponer para cada una las hipótesis y la prueba con que se contrastan, verificar sus condiciones, realizarla en R y responder la pregunta a partir del resultado.

Este ejemplo sigue esos mismos pasos con **cuatro preguntas distintas de las asignadas a los equipos**, una de cada tipo: una media, una media de diferencias pareadas, dos medias independientes y dos proporciones. En cada una partimos por **analizar la pregunta** antes de escribir una sola línea de código: qué variable la responde, qué grupos intervienen y si sus observaciones son pareadas o independientes, sobre qué parámetro se infiere, y con qué valor de referencia y en qué sentido. Las hipótesis y la prueba salen de ese análisis. Recién entonces verificamos las condiciones, realizamos la prueba y volvemos a la pregunta para responderla.

Como no hay nada en el contexto que nos obligue a ser más cautelosos, fijamos para las cuatro preguntas el nivel de significación en $\alpha = 0{,}05$.

```
alfa <- 0.05
```

Preparación de los datos

Comencemos incluyendo los paquetes que usaremos en este script.

```
library(dplyr)
library(ggpubr)
```

A continuación obtengamos los datos. El archivo usa punto y coma como separador y coma decimal, así que se lee con `read.csv2()`.

```
src_dir <- "~/Downloads"
src_basename <- "EP02-Datos.csv"
src_file <- file.path(src_dir, src_basename)

datos <- read.csv2(src_file, stringsAsFactors = TRUE)
str(datos)
```

```
'data.frame':   101 obs. of  4 variables:
 $ Id       : int  1 2 3 4 5 6 7 8 9 10 ...
 $ Zona     : Factor w/ 3 levels "Centro-Norte",..: 1 3 2 1 1 1 3 1 3 3 ...
 $ Previo   : num  12.6 12.8 12.7 12.5 12.2 ...
 $ Posterior: num  12.1 12.3 12.4 12.3 11.9 ...
```

`Id` es un **identificador**, no una cantidad, así que lo dejamos como texto. Veamos también cuántos atletas hay en cada zona, porque todas las preguntas trabajan con una o dos zonas.

```
datos[["Id"]] <- as.character(datos[["Id"]])
datos |> count(Zona)
```

```
          Zona  n
1 Centro-Norte 34
2   Centro-Sur 32
3          Sur 35
```

Hay dos variables que **no vienen en los datos** y que algunas preguntas necesitan. La primera es la **mejora** de cada atleta: cuánto bajó su marca con el entrenamiento. La calculamos como `Previo - Posterior`, para que una mejora sea un número positivo (en los 100 metros, menos tiempo es mejor). La segunda, una variable dicotómica que dice si un atleta mejoró al menos cierta cantidad de segundos, la construiremos en la pregunta que la usa, porque depende del umbral que esa pregunta fije.

```
datos <- datos |> mutate(Mejora = Previo - Posterior)
```

⚠️ **Antes de probar, hay que leer la pregunta.** Casi todos los errores de este tipo de ejercicio nacen antes de escribir H_0: mirar `Previo` cuando la pregunta habla de la mejora, comparar dos zonas cuando la pregunta es sobre una, o no ver que una proporción sale de un umbral.

Pregunta 1 · Una media

¿Es el tiempo medio de los atletas de la zona Centro-Sur tras los seis meses de entrenamiento distinto de 12,30 segundos?

Análisis de la pregunta

- **La variable** que responde la pregunta es `Posterior`, la mejor marca tras el entrenamiento, que es numérica y continua, medida en segundos.
- **El grupo** es uno solo: los atletas de la zona Centro-Sur.
- **El parámetro** es el tiempo medio en la población, μ_{CS}: la media de las marcas tras seis meses de entrenamiento que tendrían los juveniles de los juegos escolares de la zona Centro-Sur.
- **El valor de referencia** es 12,30 segundos, y la pregunta busca una diferencia **en cualquier sentido** (“distinto de”).

Hipótesis

H_0: el tiempo medio de los atletas de la zona Centro-Sur tras el entrenamiento es de 12,30 segundos ($\mu_{CS} = 12{,}30$ [s]).

H_A: el tiempo medio de los atletas de la zona Centro-Sur tras el entrenamiento es distinto de 12,30 segundos ($\mu_{CS} \neq 12{,}30$ [s]).

donde μ_{CS} es la media poblacional de las mejores marcas en los 100 metros planos, tras los seis meses de entrenamiento, de los atletas de la zona Centro-Sur.

La prueba y por qué

Se infiere sobre la media de una sola población, y **no conocemos su desviación estándar**: hay que estimarla con la de la muestra. Por eso corresponde la **prueba t para una muestra**, y no una prueba Z.

```
# Las marcas tras el entrenamiento de los atletas de Centro-Sur
marcas_1 <- datos |> filter(Zona == "Centro-Sur") |> pull(Posterior)
n_1 <- length(marcas_1)
cat("Tamaño de la muestra:", n_1, "\n")
```

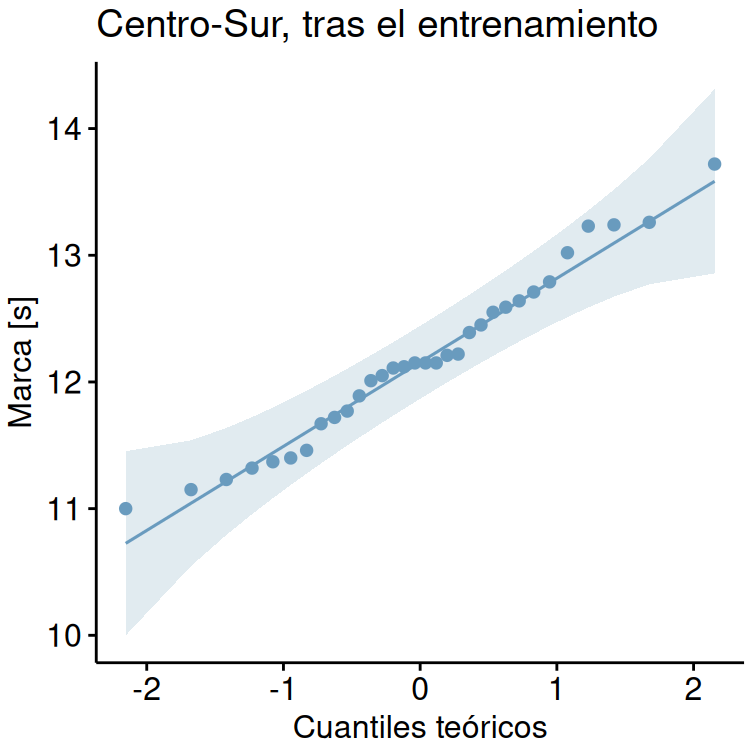
```
Tamaño de la muestra: 32
```

Condiciones

Independencia. Los 32 atletas son personas distintas, elegidas al azar entre los juveniles que corrieron en los juegos escolares, y son muchos menos del 10 % de esa población (varios miles). Podemos suponer que sus marcas son independientes entre sí.

Normalidad. La revisamos con un gráfico Q-Q de las marcas.

```
g_qq_1 <- ggqqplot(data.frame(Posterior = marcas_1), x = "Posterior",
                   color = "#6D9EC1", fill = "#BFD5E3",
                   title = "Centro-Sur, tras el entrenamiento",
                   xlab = "Cuantiles teóricos", ylab = "Marca [s]")
print(g_qq_1)
```



Los puntos siguen la recta sin una curvatura clara, y ninguno queda fuera de la banda: el gráfico no muestra asimetría ni valores atípicos. Lo complementamos con la prueba de Shapiro-Wilk.

```
normalidad_1 <- shapiro.test(marcas_1)
print(normalidad_1)
```

```

    Shapiro-Wilk normality test

data:  marcas_1
W = 0.97563, p-value = 0.6665
```

Con $W = 0{,}976$ y $p = 0{,}666$, **no hay evidencia para descartar** que las marcas provengan de una población normal. Esto no demuestra que la población sea normal: solo dice que estos datos no contradicen la condición.

La prueba en R

```
valor_nulo_1 <- 12.30
prueba_1 <- t.test(marcas_1, mu = valor_nulo_1, alternative = "two.sided",
                   conf.level = 1 - alfa)
print(prueba_1)
```

```
    One Sample t-test

data:  marcas_1
t = -1.0006, df = 31, p-value = 0.3248
alternative hypothesis: true mean is not equal to 12.3
95 percent confidence interval:
 11.93350 12.42525
sample estimates:
mean of x
 12.17938
```

Conclusión

Con $\alpha = 0{,}05$, **no rechazamos** H_0 ($t(31) = -1{,}001$; $p = 0{,}325$). Los datos **no permiten afirmar** que el tiempo medio de los atletas de la zona Centro-Sur tras el entrenamiento sea distinto de 12,30 segundos. La media de la muestra fue de 12,18 segundos, y el intervalo de 95 % de confianza para la media es [11,933; 12,425] segundos.

⚠️ **No rechazar no prueba H_0.** No concluimos que el tiempo medio "es de 12,30 segundos". El intervalo contiene 12,30, pero también muchos otros valores, como 11,94 o 12,42: con estos datos, ninguno de ellos se puede descartar.

Pregunta 2 · Una media de diferencias pareadas

¿Sugieren los datos que, en promedio, los atletas de la zona Centro-Norte mejoran su marca en más de 0,25 segundos tras el entrenamiento?

Análisis de la pregunta

- **La variable** que responde la pregunta es la **mejora**, que no viene en los datos: es `Previo − Posterior`, la que calculamos al preparar los datos.
- **El grupo** es uno solo, los atletas de Centro-Norte, pero cada uno aporta **dos marcas**: las observaciones de `Previo` y `Posterior` están **pareadas**, porque son del mismo atleta.
- **El parámetro** es la media poblacional de las mejoras, μ_d.
- **El valor de referencia** es 0,25 segundos, y el sentido es **mayor** ("en más de").

Hipótesis

H_0: en promedio, los atletas de la zona Centro-Norte mejoran su marca en 0,25 segundos tras el entrenamiento ($\mu_d = 0{,}25$ [s]).

H_A: en promedio, los atletas de la zona Centro-Norte mejoran su marca en más de 0,25 segundos tras el entrenamiento ($\mu_d > 0{,}25$ [s]).

donde $d_i = x_i^{\text{previo}} - x_i^{\text{posterior}}$ es la mejora del i-ésimo atleta, y μ_d es la media de las mejoras en la población de atletas de la zona Centro-Norte.

La prueba y por qué

Las dos marcas de un atleta no son independientes: quien era más rápido antes del programa tiende a seguir siéndolo después.

```
centro_norte <- datos |> filter(Zona == "Centro-Norte")
n_2 <- nrow(centro_norte)
cat("Tamaño de la muestra:", n_2, "atletas\n")
cat("Correlación entre Previo y Posterior:",
    round(cor(centro_norte[["Previo"]], centro_norte[["Posterior"]]), 3), "\n")
```

```
Tamaño de la muestra: 34 atletas
Correlación entre Previo y Posterior: 0.954
```

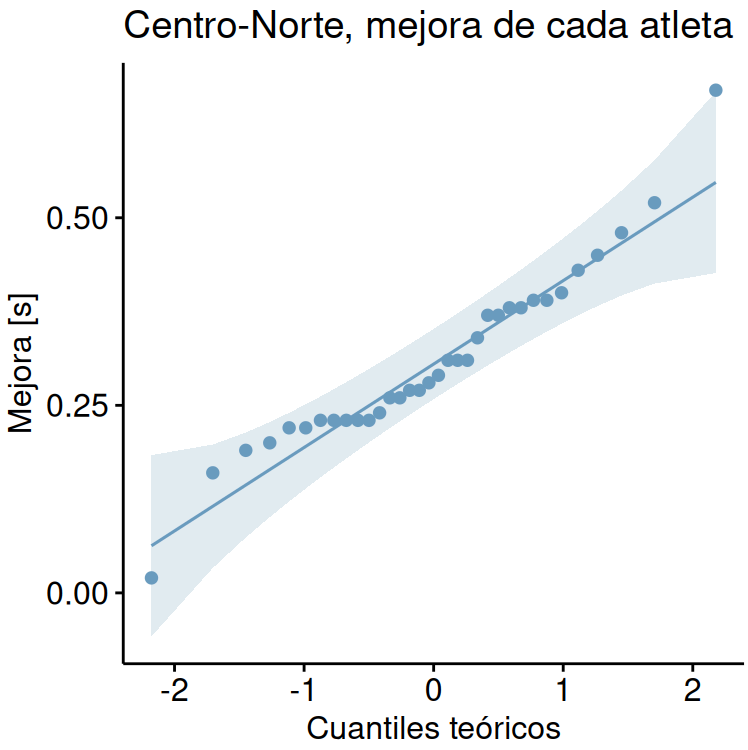
Por eso corresponde la **prueba t para muestras pareadas**, que trabaja con la diferencia dentro de cada atleta. Así, lo que separa a un atleta de otro sale del error, y queda solo lo que cambió con el entrenamiento. Una prueba para dos muestras independientes ignoraría esa correlación. Como en la pregunta 1, es una t y no una Z porque no conocemos la desviación estándar de las mejoras en la población.

Condiciones

Independencia. Los 34 atletas son distintos y elegidos al azar, y son menos del 10 % de los juveniles de los juegos escolares: los **pares** de marcas son independientes entre sí, aunque las dos marcas de un mismo par no lo sean.

Normalidad. En una prueba pareada, la condición es sobre **las diferencias**, no sobre cada marca por separado.

```
g_qq_2 <- ggqqplot(centro_norte, x = "Mejora",
                   color = "#6D9EC1", fill = "#BFD5E3",
                   title = "Centro-Norte, mejora de cada atleta",
                   xlab = "Cuantiles teóricos", ylab = "Mejora [s]")
print(g_qq_2)
```



Los puntos siguen la recta y quedan dentro de la banda: el gráfico no muestra un alejamiento de la normalidad. La prueba de Shapiro-Wilk apunta a lo mismo.

```
normalidad_2 <- shapiro.test(centro_norte[["Mejora"]])
print(normalidad_2)
```

```

    Shapiro-Wilk normality test

data:  centro_norte[["Mejora"]]
W = 0.94924, p-value = 0.1165
```

Con $p = 0{,}117$, no hay evidencia para descartar que las mejoras provengan de una población normal.

La prueba en R

⚠ **El orden de los argumentos decide el signo.** `t.test(x, y, paired = TRUE)` calcula `x − y`. Como definimos la mejora como `Previo − Posterior`, `Previo` va primero; si pusiéramos `Posterior` primero, las diferencias saldrían negativas, y habría que usar `mu = -0.25` y `alternative = "less"`.

```
valor_nulo_2 <- 0.25
prueba_2 <- t.test(centro_norte[["Previo"]], centro_norte[["Posterior"]],
                   paired = TRUE, mu = valor_nulo_2, alternative = "greater",
                   conf.level = 1 - alfa)
print(prueba_2)
```

```
    Paired t-test

data:  centro_norte[["Previo"]] and centro_norte[["Posterior"]]
t = 2.9138, df = 33, p-value = 0.003183
alternative hypothesis: true mean difference is greater than 0.25
95 percent confidence interval:
 0.2750281       Inf
sample estimates:
mean difference
      0.3097059
```

Conclusión

Con $\alpha = 0{,}05$, **rechazamos** H_0 en favor de H_A ($t(33) = 2{,}914$; $p = 0{,}003$). Los datos sugieren que, en promedio, los atletas de la zona Centro-Norte mejoran su marca en más de 0,25 segundos tras los seis meses de entrenamiento. La mejora media de la muestra fue de 0,310 segundos, y el intervalo unilateral de 95 % de confianza para la mejora media es [0,275; ∞) segundos.

Pregunta 3 · Dos medias independientes

¿Es posible afirmar que, tras los seis meses de entrenamiento, el tiempo medio de los atletas de la zona Centro-Sur es mayor que el de los de la zona Sur en más de 0,30 segundos?

Análisis de la pregunta

- **La variable** es `Posterior`, la marca tras el entrenamiento.
- **Los grupos** son dos, los atletas de Centro-Sur y los de Sur, y sus observaciones son **independientes**: son atletas distintos, sin ningún pareo entre ellos.
- **El parámetro** es la diferencia entre las medias de las dos poblaciones, $\mu_{CS} - \mu_S$, en ese orden: la pregunta pone a Centro-Sur primero.
- **El valor de referencia** es 0,30 segundos, y el sentido es **mayor** (“en más de”).

Hipótesis

H_0: tras el entrenamiento, el tiempo medio de los atletas de la zona Centro-Sur es mayor que el de los de la zona Sur en 0,30 segundos ($\mu_{CS} - \mu_S = 0{,}30$ [s]).

H_A: tras el entrenamiento, el tiempo medio de los atletas de la zona Centro-Sur es mayor que el de los de la zona Sur en más de 0,30 segundos ($\mu_{CS} - \mu_S > 0{,}30$ [s]).

donde μ_{CS} y μ_S son las medias poblacionales de las mejores marcas tras el entrenamiento de los atletas de las zonas Centro-Sur y Sur, respectivamente.

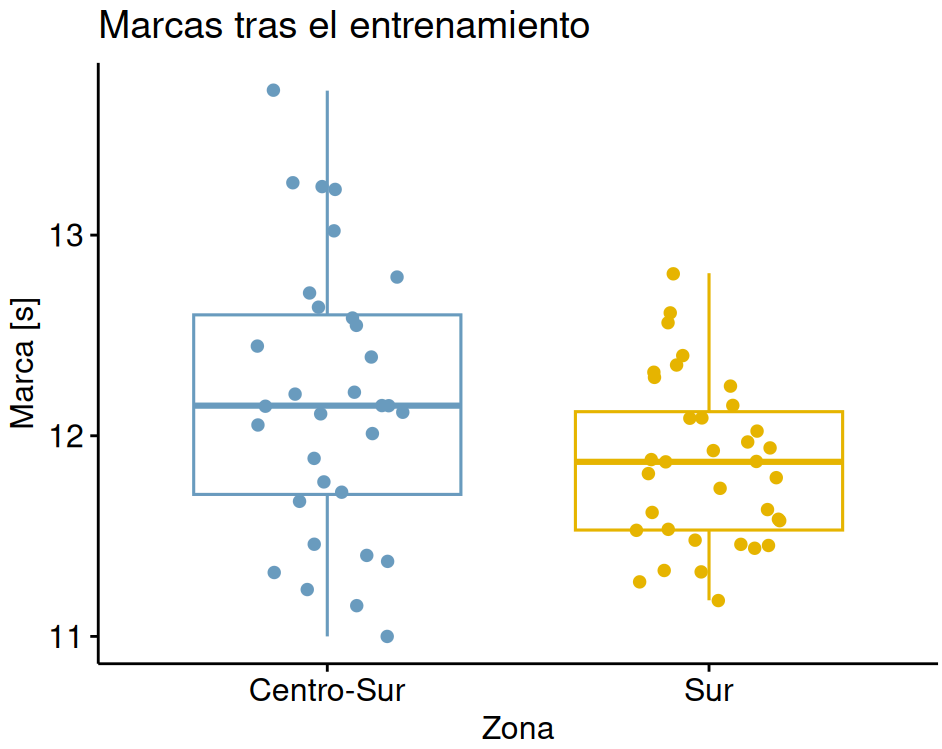
La prueba y por qué

Se comparan las medias de dos poblaciones independientes sin conocer sus desviaciones estándar: corresponde una **prueba t para dos muestras independientes**. Queda una decisión: si suponemos que las dos poblaciones tienen la misma varianza (Student) o no (Welch). Miremos la dispersión de cada muestra.

```
dos_zonas <- datos |> filter(Zona %in% c("Centro-Sur", "Sur")) |> droplevels()
dos_zonas |>
  group_by(Zona) |>
  summarise(n = n(), media = mean(Posterior), desv = sd(Posterior))
```

```
# A tibble: 2 × 4
  Zona           n media  desv
  <fct>      <int> <dbl> <dbl>
1 Centro-Sur    32  12.2 0.682
2 Sur           35  11.9 0.414
```

```
g_caja_3 <- ggboxplot(dos_zonas, x = "Zona", y = "Posterior",
                      color = "Zona", palette = c("#6D9EC1", "#E7B800"), add = "jitter",
                      title = "Marcas tras el entrenamiento",
                      xlab = "Zona", ylab = "Marca [s]", legend = "none")
print(g_caja_3)
```



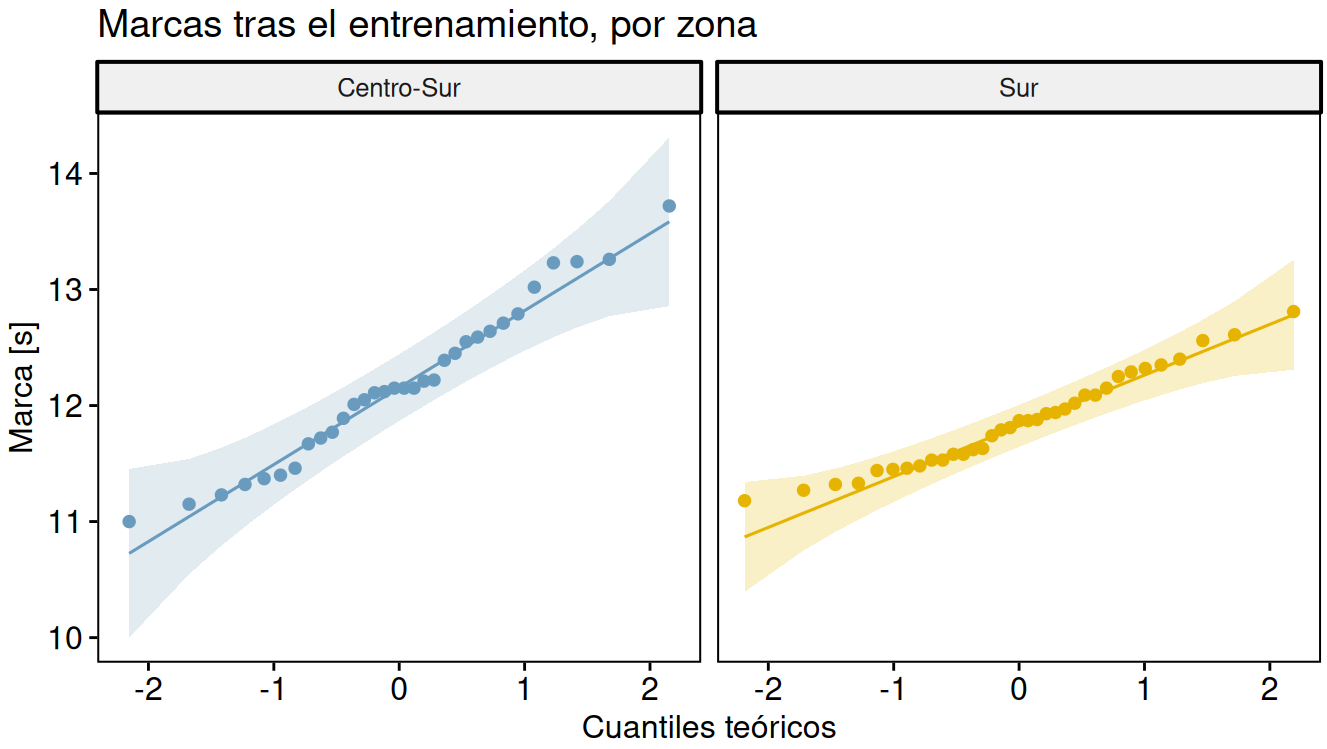
La caja de Centro-Sur es bastante más alta, y su desviación estándar (0,682 s) es 1,6 veces la de Sur (0,414 s). No tenemos razones para suponer varianzas iguales, así que usamos la **prueba t de Welch**, que no lo exige.

Condiciones

Independencia. Los atletas de cada zona fueron elegidos al azar y son menos del 10 % de los juveniles de los juegos escolares, así que las marcas son independientes dentro de cada muestra. Y como son atletas distintos, las dos muestras son independientes entre sí.

Normalidad. En esta prueba, la condición es sobre **cada** muestra.

```
g_qq_3 <- ggqqplot(dos_zonas, x = "Posterior", facet.by = "Zona",
                   color = "Zona", palette = c("#6D9EC1", "#E7B800"),
                   title = "Marcas tras el entrenamiento, por zona",
                   xlab = "Cuantiles teóricos", ylab = "Marca [s]", legend = "none")
print(g_qq_3)
```



En los dos gráficos los puntos siguen la recta y quedan dentro de la banda. Shapiro-Wilk, aplicada a cada zona, tampoco da evidencia contra la normalidad.

```
dos_zonas |>
  group_by(Zona) |>
  summarise(W = shapiro.test(Posterior)$statistic, p = shapiro.test(Posterior)$p.value)
```

```
# A tibble: 2 × 3
  Zona           W     p
  <fct>      <dbl> <dbl>
1 Centro-Sur 0.976 0.666
2 Sur        0.970 0.444
```

La prueba en R

⚠️ **El orden de los grupos también decide el signo.** `t.test(x, y)` estima `media(x) − media(y)`. Las hipótesis hablan de $\mu_{CS} - \mu_S$, así que Centro-Sur va como `x`. `var.equal = FALSE` es el valor por omisión, que da la prueba de Welch; lo escribimos para que se vea la decisión.

```
centro_sur_3 <- dos_zonas |> filter(Zona == "Centro-Sur") |> pull(Posterior)
sur_3 <- dos_zonas |> filter(Zona == "Sur") |> pull(Posterior)
valor_nulo_3 <- 0.30
prueba_3 <- t.test(x = centro_sur_3, y = sur_3, var.equal = FALSE,
                   mu = valor_nulo_3, alternative = "greater", conf.level = 1 - alfa)
print(prueba_3)
```

```
    Welch Two Sample t-test

data:  centro_sur_3 and sur_3
t = 0.13083, df = 50.174, p-value = 0.4482
alternative hypothesis: true difference in means is greater than 0.3
95 percent confidence interval:
 0.08470295        Inf
sample estimates:
mean of x mean of y
 12.17938  11.86114
```

Conclusión

Con $\alpha = 0{,}05$, **no rechazamos** H_0 ($t(50{,}2) = 0{,}131$; $p = 0{,}448$). Los datos **no permiten afirmar** que, tras el entrenamiento, el tiempo medio de los atletas de la zona Centro-Sur supere al de los de la zona Sur en más de 0,30 segundos. La diferencia entre las medias de las muestras fue de 0,318 segundos, y el intervalo unilateral de 95 % de confianza para la diferencia es [0,085; ∞) segundos.

⚠️ **La muestra apunta hacia H_A, y aun así no rechazamos.** La diferencia observada, 0,32 segundos, es mayor que 0,30, pero por tan poco que podría deberse al azar del muestreo. Tampoco podemos concluir que la diferencia "es de 0,30 segundos": el intervalo contiene valores bastante menores.

Pregunta 4 · Dos proporciones

¿Es mayor la proporción de atletas de la zona Centro-Sur que mejoraron su marca en al menos 0,35 segundos que la de los atletas de la zona Centro-Norte?

Análisis de la pregunta

- **La variable** es dicotómica y **no viene en los datos**: si un atleta mejoró al menos 0,35 segundos o no. Se construye a partir de la mejora.
- **Los grupos** son dos, Centro-Sur y Centro-Norte, y son **independientes**: atletas distintos.
- **El parámetro** es la diferencia entre las proporciones de las dos poblaciones, $p_{CS} - p_{CN}$, con Centro-Sur primero, como en la pregunta.
- **El valor de referencia** es 0, porque la pregunta compara las dos proporciones entre sí, y el sentido es **mayor**. Los 0,35 segundos **no son el valor nulo**: son el umbral que define la variable.

Hipótesis

H_0: la proporción de atletas que mejoraron su marca en al menos 0,35 segundos es la misma en las zonas Centro-Sur y Centro-Norte ($p_{CS} - p_{CN} = 0$).

H_A: la proporción de atletas que mejoraron su marca en al menos 0,35 segundos es mayor en la zona Centro-Sur que en la zona Centro-Norte ($p_{CS} - p_{CN} > 0$).

donde p_{CS} y p_{CN} son las proporciones de atletas que mejoran su marca en al menos 0,35 segundos tras el entrenamiento en las poblaciones de las zonas Centro-Sur y Centro-Norte, respectivamente.

La prueba y por qué

La variable es dicotómica y se comparan dos poblaciones independientes: corresponde la **prueba para la diferencia de dos proporciones**, que en R hace `prop.test()`. Primero construimos la variable y contamos éxitos (mejoró al menos 0,35 segundos) y fracasos en cada zona.

```
umbral_4 <- 0.35
conteo_4 <- datos |>
  filter(Zona %in% c("Centro-Sur", "Centro-Norte")) |>
  mutate(Mejoro = Mejora >= umbral_4) |>
  group_by(Zona) |>
  summarise(exitos = sum(Mejoro), fracasos = sum(!Mejoro), n = n())
conteo_4
```

```
# A tibble: 2 × 4
  Zona         exitos fracasos     n
  <fct>         <int>    <int> <int>
1 Centro-Norte     12       22    34
2 Centro-Sur       22       10    32
```

Condiciones

Independencia. Como en las preguntas anteriores, los atletas fueron elegidos al azar, son menos del 10 % de su población y son distintos en las dos zonas.

Éxitos y fracasos. Para usar el modelo normal, cada grupo necesita **al menos 10 éxitos y 10 fracasos**, contados en los datos. La tabla de arriba los tiene: el valor más bajo es 10, justo en el límite. En esta prueba no hay normalidad de los datos que verificar: la variable es sí o no.

La prueba en R

`prop.test()` recibe los éxitos y los tamaños de los dos grupos, en el mismo orden que las hipótesis: Centro-Sur primero. Por omisión aplica la corrección de continuidad de Yates, que la hace algo más conservadora; la dejamos.

```
exitos_4 <- c(conteo_4$exitos[conteo_4$Zona == "Centro-Sur"],
              conteo_4$exitos[conteo_4$Zona == "Centro-Norte"])
n_4 <- c(conteo_4$n[conteo_4$Zona == "Centro-Sur"],
         conteo_4$n[conteo_4$Zona == "Centro-Norte"])
prueba_4 <- prop.test(x = exitos_4, n = n_4, alternative = "greater",
                      conf.level = 1 - alfa)
print(prueba_4)
```

```

    2-sample test for equality of proportions with continuity correction

data:  exitos_4 out of n_4
X-squared = 6.1086, df = 1, p-value = 0.006726
alternative hypothesis: greater
95 percent confidence interval:
 0.1136041 1.0000000
sample estimates:
   prop 1    prop 2
0.6875000 0.3529412
```

Conclusión

Con $\alpha = 0{,}05$, **rechazamos** H_0 en favor de H_A ($\chi^2(1) = 6{,}109$; $p = 0{,}007$). Los datos sugieren que la proporción de atletas que mejoran su marca en al menos 0,35 segundos tras el entrenamiento es mayor en la zona Centro-Sur (0,688 en la muestra) que en la zona Centro-Norte (0,353). Según el intervalo unilateral de 95 % de confianza, la diferencia entre las dos proporciones se encuentra entre 11,4 y 100 puntos porcentuales.

⚠️ **Una diferencia no dice por qué existe.** Los atletas no se asignaron al azar a las zonas: los de Centro-Sur pueden diferir de los de Centro-Norte en otras cosas, como su marca inicial, que era más lenta y dejaba más margen para mejorar. La prueba dice que la diferencia es más que azar, no que se deba a los centros de entrenamiento.