Inferencia no paramétrica con frecuencias

Ejemplo de solución ejercicio práctico N°4

Este ejemplo resuelve cuatro preguntas, una por cada prueba de la lectura 5, como se pide en el ejercicio: la prueba elegida y por qué, sus condiciones, sus hipótesis, la prueba en R, si hace falta un procedimiento *post hoc* y la conclusión.

Cada una de las cuatro preguntas tiene un problema en cómo se recogieron los datos, como el que escondía uno de los enunciados de cada equipo. Por eso, al verificar las condiciones, cada pregunta termina con lo que pedía la pregunta incógnita: qué condición falla y por qué, qué consecuencia tiene para la conclusión y qué cambiaríamos en el diseño del estudio.

Preparación

Comencemos cargando los paquetes que usaremos y fijando el nivel de significación de todas las preguntas.

```
# Cargar los paquetes
library(dplyr)
library(rcompanion)
library(RVAideMemoire)
library(tidyr)

# Fijar el nivel de significación
alfa <- 0.05
```

Pregunta 1 · Prueba exacta de Fisher

Un departamento de ingeniería quiere saber si el lenguaje de programación preferido para un primer proyecto se relaciona con la experiencia de quien lo elige. Se eligió al azar a 9 estudiantes de primer año y se le preguntó a cada uno, y a su tutor o tutora de cuarto año, por separado, si prefería Python o Java. 8 de los 9 estudiantes y 2 de los 9 tutores eligieron Python. ¿Hay relación entre la experiencia y el lenguaje preferido?

La prueba

Se cruzan dos variables dicotómicas, la experiencia (primer año o cuarto año) y el lenguaje preferido (Python o Java), y se comparan dos grupos de personas distintas. Con tan pocas personas, la prueba puede ser la exacta de Fisher o una χ^2, según las frecuencias esperadas: si alguna es menor que 5, corresponde la de Fisher.

Construimos la tabla de frecuencias observadas y calculamos las frecuencias esperadas si el lenguaje no dependiera del grupo: el total de su fila por el total de su columna, dividido por el total de la tabla.

```
# Crear la tabla de frecuencias observadas
tabla_1 <- matrix(c(8, 2, 1, 7), nrow = 2,
                  dimnames = list(Grupo = c("Primer año", "Tutor"),
                                  Lenguaje = c("Python", "Java")))

# Mostrar la tabla de frecuencias observadas
cat("Frecuencias observadas\n")
cat("----------------------\n")
print(tabla_1)

# Calcular las frecuencias esperadas si las variables fueran independientes
esperadas_1 <- outer(rowSums(tabla_1), colSums(tabla_1)) / sum(tabla_1)

# Mostrar la tabla de frecuencias esperadas
cat("\nFrecuencias esperadas\n")
cat("---------------------\n")
print(esperadas_1)
```

```
Frecuencias observadas
----------------------
            Lenguaje
Grupo        Python Java
  Primer año      8    1
  Tutor           2    7

Frecuencias esperadas
---------------------
           Python Java
Primer año      5    4
Tutor           5    4
```

Dos de las cuatro frecuencias esperadas son 4, menores que 5, así que usamos la **prueba exacta de Fisher**.

Las condiciones

- Las dos variables son dicotómicas: el grupo y el lenguaje.
- Las observaciones tienen que ser independientes entre sí. Los estudiantes se eligieron al azar, y 9 son mucho menos del 10 % de quienes cursan primer año. Pero **los tutores no se eligieron por su cuenta**: cada uno es el tutor de uno de esos estudiantes.

⚠️ **Esta es la condición que falla: la independencia entre los dos grupos.** Cada estudiante va con su propio tutor, así que las dos muestras están **apareadas**, no son independientes. Y es esperable que se parezcan: el tutor acompaña al estudiante en su primer proyecto y puede influir en el lenguaje que elige.

Igual aplicamos la prueba, para ver qué habría concluido el departamento.

Las hipótesis

- H_0: el lenguaje preferido es independiente de la experiencia (primer año o cuarto año).
- H_A: el lenguaje preferido está relacionado con la experiencia.

La prueba en R

Aplicamos la prueba exacta de Fisher a la tabla de frecuencias observadas.

```
# Aplicar la prueba exacta de Fisher y mostrar su resultado
prueba_1 <- fisher.test(tabla_1)
print(prueba_1)
```

```
    Fisher's Exact Test for Count Data

data:  tabla_1
p-value = 0.01522
alternative hypothesis: true odds ratio is not equal to 1
95 percent confidence interval:
    1.533351 1396.017102
sample estimates:
odds ratio
  21.39941
```

El valor p es menor que el nivel de significación, así que la prueba rechaza la hipótesis nula. La razón de *odds* estimada es muy alta y su intervalo de confianza no contiene el 1, de modo que coincide con la prueba; es muy ancho porque hay muy pocas personas.

Es una tabla de 2 × 2: hay una sola comparación, así que no hace falta un procedimiento *post hoc*.

La conclusión

Con un nivel de significación de 0,05, la prueba rechaza la hipótesis nula (p = 0,015): el lenguaje preferido estaría relacionado con la experiencia. En la muestra, 8 de los 9 estudiantes de primer año prefieren Python, contra 2 de los 9 tutores, y la razón de *odds* estimada es 21,4. **Pero no podemos confiar en esta conclusión**, porque la prueba supone dos muestras independientes, y no lo son.

Lo que falla en el diseño

- **La condición que falla** es la independencia entre las dos muestras: cada tutor está ligado a un estudiante de la otra muestra.
- **La consecuencia:** la prueba trata a las 18 personas como si nada las uniera. Como no es así, no se puede confiar en su valor p ni en la conclusión. Si lo que interesa es comparar a cada estudiante con su tutor, los datos son apareados, y la prueba tendría que ser otra.
- **El cambio en el diseño:** elegir a los tutores al azar y por separado, sin relación con los estudiantes de la muestra (por ejemplo, tutores de otros estudiantes). Si interesara justamente el par, habría que registrar la respuesta de cada par y analizar los datos como apareados.

Pregunta 2 · Prueba de McNemar

Una empresa quiere evaluar un taller de seguridad informática. Se eligieron al azar 8 de sus equipos de trabajo, de 4 personas cada uno, que hicieron el taller juntos. Antes y después del taller, se registró si cada persona reconocía un correo de *phishing*: 5 lo reconocieron antes y después, 12 no lo reconocieron ni antes ni después, 13 aprendieron a reconocerlo y 2 dejaron de reconocerlo. ¿Mejoró el taller la capacidad de reconocer correos de *phishing*?

La prueba

Se mide una variable dicotómica (reconoce o no un correo de *phishing*) dos veces en las mismas personas, antes y después del taller: son datos apareados. La prueba que corresponde es la **prueba de McNemar**.

Construimos la tabla de frecuencias, con las mediciones de antes en las filas y las de después en las columnas, y contamos los cambios: las personas que pasaron de reconocer a no reconocer (b) y las que pasaron de no reconocer a reconocer (c).

```
# Crear la tabla de frecuencias observadas: antes en las filas, después en las columnas
tabla_2 <- matrix(c(5, 13, 2, 12), nrow = 2,
                  dimnames = list(Antes = c("Reconoce", "No reconoce"),
                                  Después = c("Reconoce", "No reconoce")))

# Mostrar la tabla de frecuencias observadas
cat("Frecuencias observadas\n")
cat("----------------------\n")
print(tabla_2)

# Contar y mostrar los cambios, en un sentido (b) y en el otro (c)
cambios <- tabla_2["Reconoce", "No reconoce"] + tabla_2["No reconoce", "Reconoce"]
cat("\nCambios (b + c):", cambios, "\n")
```

```
Frecuencias observadas
----------------------
             Después
Antes         Reconoce No reconoce
  Reconoce           5           2
  No reconoce       13          12

Cambios (b + c): 15
```

Hubo 15 cambios: 2 en un sentido y 13 en el otro.

Las condiciones

- La variable es dicotómica y se mide dos veces en las mismas personas.
- Hay 15 cambios, más de 10, así que podemos usar la aproximación de la prueba.
- Los casos tienen que ser independientes entre sí: lo que pase con una persona no debería influir en lo que pase con otra. Los equipos se eligieron al azar, y 32 personas son menos del 10 % de la empresa. Pero **las personas no se eligieron por separado**: vienen en grupos de 4 que trabajan juntos.

⚠️ **Esta es la condición que falla: la independencia entre los casos.** Las personas de un mismo equipo comparten oficina, reciben los mismos correos, conversan entre ellas e hicieron el taller juntas. Lo que aprende una probablemente lo aprende su equipo: los datos vienen en **conglomerados**.

Igual aplicamos la prueba, para ver qué habría concluido la empresa.

Las hipótesis

- H_0: en la población, los cambios de no reconocer a reconocer un correo de *phishing* son tan frecuentes como los cambios en el sentido contrario.
- H_A: en la población, los cambios en un sentido son más frecuentes que en el otro.

La prueba en R

Aplicamos la prueba de McNemar a la tabla, en su versión sin corrección de continuidad, como recomienda la lectura (la función la aplica por omisión).

```
# Aplicar la prueba de McNemar sin corrección de continuidad y mostrar su resultado
prueba_2 <- mcnemar.test(tabla_2, correct = FALSE)
print(prueba_2)
```

```

    McNemar's Chi-squared test

data:  tabla_2
McNemar's chi-squared = 8.0667, df = 1, p-value = 0.004509
```

El valor p es menor que el nivel de significación, así que la prueba rechaza la hipótesis nula.

Es una tabla de 2 × 2: hay una sola comparación, así que no hace falta un procedimiento *post hoc*.

La conclusión

Con un nivel de significación de 0,05, la prueba rechaza la hipótesis nula ($\chi^2(1)$ = 8,07; p = 0,005): 13 personas aprendieron a reconocer el *phishing* y solo 2 dejaron de hacerlo, así que el taller habría mejorado esa capacidad. **Pero no podemos confiar en esta conclusión**, porque los casos no son independientes.

Lo que falla en el diseño

- **La condición que falla** es la independencia entre los casos: las 32 personas son 8 grupos de 4 que trabajan y aprendieron juntas.
- **La consecuencia:** la prueba trata a las 32 personas como si cada una aportara información propia. Como las de un mismo equipo se parecen, no se puede confiar en el valor p ni en la conclusión.
- **El cambio en el diseño:** elegir a las personas al azar y por separado, de distintos equipos (una por equipo), y que cada una haga el taller y las pruebas sin compartirlos con las demás de la muestra.

Pregunta 3 · Prueba χ^2 de homogeneidad

Un sistema de bicicletas compartidas quiere saber si la duración de los viajes (corto, medio o largo) se distribuye igual en dos de sus estaciones, Plaza y Campus. Se eligieron al azar 40 viajes de cada estación del registro de una semana de marzo. En Plaza hubo 22 viajes cortos, 12 medios y 6 largos, y en Campus, 10, 16 y 14. ¿Es igual la distribución de la duración de los viajes en las dos estaciones?

La prueba

Se compara la distribución de una variable categórica con tres niveles (la duración) en dos poblaciones (los viajes de cada estación), con una muestra de cada una. La prueba que corresponde es la **prueba χ^2 de homogeneidad**, si se cumplen sus condiciones.

Construimos la tabla de frecuencias observadas, con una fila por estación.

```
# Crear la tabla de frecuencias observadas: una fila por estación
tabla_3 <- matrix(c(22, 10, 12, 16, 6, 14), nrow = 2,
                  dimnames = list(Estación = c("Plaza", "Campus"),
                                  Duración = c("Corto", "Medio", "Largo")))

# Mostrar la tabla de frecuencias observadas
cat("Frecuencias observadas\n")
cat("----------------------\n")
print(tabla_3)
```

```
Frecuencias observadas
----------------------
        Duración
Estación Corto Medio Largo
  Plaza     22    12     6
  Campus    10    16    14
```

Las condiciones

- Cada celda tiene que esperar al menos 5 observaciones. Las frecuencias esperadas las entrega la misma prueba, así que las revisamos al aplicarla, más abajo.
- Las observaciones tienen que ser independientes entre sí. Los viajes se eligieron al azar, y 40 son mucho menos del 10 % de los viajes de una semana en cada estación. Pero **los viajes no son las personas que viajan**.

⚠️ **Esta es la condición que falla: la independencia de las observaciones.** Una misma persona puede hacer muchos viajes en una semana (por ejemplo, ida y vuelta todos los días), así que puede aparecer varias veces en la muestra de una estación, e incluso en las dos. Sus viajes se parecen entre sí: si esa persona vive cerca, todos sus viajes son cortos.

Igual aplicamos la prueba, para ver qué habría concluido el sistema.

Las hipótesis

- H_0: la duración de los viajes tiene la misma distribución en las dos estaciones.
- H_A: la duración de los viajes tiene distinta distribución en las dos estaciones.

La prueba en R

Aplicamos la prueba a la tabla y mostramos, antes de su resultado, las frecuencias esperadas que calcula, para verificar esa condición.

```
# Aplicar la prueba chi-cuadrado de homogeneidad
prueba_3 <- chisq.test(tabla_3)

# Mostrar las frecuencias esperadas, para verificar la condición, y el resultado
cat("Frecuencias esperadas\n")
cat("---------------------\n")
print(prueba_3$expected)
print(prueba_3)
```

```
Frecuencias esperadas
---------------------
        Duración
Estación Corto Medio Largo
  Plaza     16    14    10
  Campus    16    14    10

    Pearson's Chi-squared test

data:  tabla_3
X-squared = 8.2714, df = 2, p-value = 0.01599
```

La menor frecuencia esperada es 10, mayor que 5, así que se cumple la condición. El valor p es menor que el nivel de significación, así que la prueba rechaza la hipótesis nula. Como es una prueba ómnibus, **hace falta un procedimiento *post hoc*** para saber en qué duraciones difieren las estaciones.

Como en la lectura, comparamos cada duración con el resto de ellas en una tabla de 2 × 2, con pruebas χ^2 sin la corrección de continuidad, y ajustamos los valores p con el método de Holm. Cada una de esas pruebas tiene las mismas condiciones que la ómnibus, así que primero las aplicamos y mostramos la menor frecuencia esperada de las tres tablas.

```
# Construir, para cada duración, la tabla de 2 × 2 de esa duración contra el resto
duraciones <- colnames(tabla_3)
tablas_ph <- lapply(duraciones, function(d)
  cbind(tabla_3[, d], rowSums(tabla_3[, colnames(tabla_3) != d])))

# Aplicar a cada tabla una prueba chi-cuadrado, sin corrección de continuidad
pruebas_ph <- lapply(tablas_ph, chisq.test, correct = FALSE)

# Mostrar la menor frecuencia esperada de las comparaciones, para verificar la condición
cat("Menor frecuencia esperada en las comparaciones:",
    min(sapply(pruebas_ph, function(p) min(p$expected))), "\n")
```

```
Menor frecuencia esperada en las comparaciones: 10
```

Es mayor que 5, así que las tres comparaciones pueden hacerse con la prueba χ^2; si alguna no cumpliera la condición, esa comparación tendría que hacerse con la prueba exacta de Fisher.

Ahora reunimos, para cada duración, su proporción en cada estación y los valores p de las tres comparaciones, sin ajustar y ajustados con el método de Holm.

```
# Obtener los valores p de las comparaciones
p_valores <- sapply(pruebas_ph, function(p) p$p.value)

# Reunir la proporción de cada duración en cada estación y los valores p, sin ajustar
# y ajustados con el método de Holm, y mostrarlos.
resultado_ph <- data.frame(Duración = duraciones,
                           Plaza = round(tabla_3["Plaza", ] / sum(tabla_3["Plaza", ]),
3),
                           Campus = round(tabla_3["Campus", ] / sum(tabla_3["Campus",
]), 3),
                           p = round(p_valores, 4),
                           p_Holm = round(p.adjust(p_valores, method = "holm"), 4))
print(resultado_ph, row.names = FALSE)
```

```
 Duración Plaza Campus      p p_Holm
    Corto  0.55   0.25 0.0062 0.0185
    Medio  0.30   0.40 0.3484 0.3484
    Largo  0.15   0.35 0.0389 0.0777
```

Con el ajuste de Holm, solo la comparación de los viajes cortos es significativa: en Plaza son una proporción mayor que en Campus.

La conclusión

Con un nivel de significación de 0,05, la prueba rechaza la hipótesis nula ($\chi^2(2)$ = 8,27; p = 0,016): la duración de los viajes no tendría la misma distribución en las dos estaciones. Según el procedimiento *post hoc*, la diferencia está en los viajes cortos: son el 55 % en Plaza y el 25 % en Campus. Para los medios y los largos no hay evidencia suficiente de una diferencia. **Pero no podemos confiar en esta conclusión**, porque las observaciones no son independientes.

Lo que falla en el diseño

- **La condición que falla** es la independencia de las observaciones: una misma persona puede aportar varios viajes, en una estación o en las dos.
- **La consecuencia:** la prueba cuenta 80 viajes como si fueran 80 observaciones independientes, pero muchos pueden ser de las mismas personas. No se puede confiar en el valor p ni en la conclusión.
- **El cambio en el diseño:** elegir al azar personas usuarias de cada estación, que no usen la otra, y registrar un viaje por persona.

Pregunta 4 · Prueba Q de Cochran

Una empresa de bebidas quiere saber si a la gente le gustan por igual tres versiones de una bebida isotónica, A, B y C. Se eligió al azar a 16 personas, que probaron las tres versiones en una misma sesión, sentadas en una mesa común y comentando cada muestra en voz alta antes de anotar si les gustaba (1) o no (0). Los resultados fueron los siguientes:

Persona	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
A	1	1	1	1	1	1	1	1	1	1	1	1	0	1	0	1
B	0	0	1	0	0	0	1	0	0	0	0	0	1	0	0	0
C	1	0	1	1	1	0	1	1	1	0	1	1	0	1	1	1

¿Les gustan por igual las tres versiones?

La prueba

Se mide una variable dicotómica (gusta o no) en tres condiciones (las versiones) en las mismas personas: cada persona es un bloque. La prueba que corresponde es la **prueba Q de Cochran**.

Cargamos los datos en formato ancho, una fila por persona, y los llevamos a formato largo, una fila por medición, que es como los pide la función de la prueba. Al final mostramos a cuántas personas les gustó cada versión.

```
# Crear la matriz de datos en formato ancho: una fila por persona
persona <- 1:16
A <- c(1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 0, 1)
B <- c(0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 0, 0)
C <- c(1, 0, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 0, 1, 1, 1)
datos_anchos <- data.frame(persona, A, B, C)

# Llevar los datos a formato largo: una fila por medición, con la persona como bloque
datos_largos <- datos_anchos |>
  pivot_longer(c("A", "B", "C"), names_to = "version", values_to = "gusta") |>
  mutate(persona = factor(persona), version = factor(version))

# Mostrar a cuántas personas les gustó cada versión
cat("Personas a las que les gustó cada versión:\n")
print(colSums(datos_anchos[, c("A", "B", "C")]))
```

```
Personas a las que les gustó cada versión:
 A  B  C
14  3 12
```

Las condiciones

- La variable de respuesta es dicotómica (gusta o no).
- La variable independiente, la versión de la bebida, es categórica, con tres niveles.
- El tamaño de la muestra: hay 16 bloques y 3 tratamientos, y $16 \cdot 3 = 48 \geq 24$.
- Los bloques tienen que ser independientes entre sí: lo que opine una persona no debería influir en lo que opine otra. Las personas se eligieron al azar, y 16 son mucho menos del 10 % de quienes podrían tomar esta bebida. Pero **probaron juntas y comentando en voz alta**.

⚠️ **Esta es la condición que falla: la independencia entre los bloques.** Cada persona escuchó lo que dijeron las demás antes de anotar si le gustaba: un comentario entusiasta o un gesto de disgusto pueden arrastrar a la mesa.

Igual aplicamos la prueba, para ver qué habría concluido la empresa.

Las hipótesis

- H_0: la proporción de personas a las que les gusta la bebida es la misma en las tres versiones.
- H_A: la proporción de personas a las que les gusta la bebida es distinta en al menos una versión.

La prueba en R

Aplicamos la prueba Q de Cochran a los datos en formato largo, con la persona como bloque.

```
# Aplicar la prueba Q de Cochran y mostrar su resultado
prueba_4 <- cochran.qtest(gusta ~ version | persona, data = datos_largos, alpha = alfa)
print(prueba_4)
```

```
    Cochran's Q test

data:  gusta by version, block = persona
Q = 14.7143, df = 2, p-value = 0.000638
alternative hypothesis: true difference in probabilities is not equal to 0
sample estimates:
proba in group A proba in group B proba in group C
          0.8750           0.1875           0.7500

        Pairwise comparisons using Wilcoxon sign test

        A       B
B 0.01025       -
C 0.62500 0.01758

P value adjustment method: fdr
```

El valor p es menor que el nivel de significación, así que la prueba rechaza la hipótesis nula. La función agrega comparaciones por pares, pero con su propia prueba y su propio ajuste, así que no las usamos. Como es una prueba ómnibus, **hace falta un procedimiento *post hoc***.

Como en la lectura, aplicamos la prueba de McNemar a cada par de versiones, sin corrección de continuidad, con el ajuste de Holm.

```
# Aplicar la prueba de McNemar a cada par de versiones, sin corrección de continuidad
# y con el ajuste de Holm, y mostrar el resultado.
post_hoc_4 <- pairwiseMcnemar(gusta ~ version | persona, data = datos_largos,
                              test = "mcnemar", correct = FALSE, method = "holm")
print(post_hoc_4)
```

```
$Test.method
     Test
1 mcnemar

$Adustment.method
  Method
1   holm

$Pairwise
  Comparison chi.sq df p.value p.adjust
1  A - B = 0   9.31  1 0.00228  0.00684
2  A - C = 0      1  1   0.317  0.31700
3  B - C = 0   7.36  1 0.00666  0.01330
```

Con el ajuste de Holm, B difiere de A y de C, y A y C no difieren.

La conclusión

Con un nivel de significación de 0,05, la prueba rechaza la hipótesis nula ($Q = 14{,}71$, con 2 grados de libertad; $p < 0{,}001$): la proporción de personas a las que les gusta la bebida no sería la misma en las tres versiones. Según el procedimiento *post hoc*, la versión B gusta menos que la A (a 3 personas contra 14) y que la C (contra 12), y no hay evidencia suficiente de una diferencia entre A y C. **Pero no podemos confiar en esta conclusión**, porque los bloques no son independientes.

Lo que falla en el diseño

- **La condición que falla** es la independencia entre los bloques: cada persona pudo influir en las demás.
- **La consecuencia:** la prueba trata a las 16 personas como 16 opiniones independientes, pero pueden ser en parte la opinión de la mesa. No se puede confiar en el valor p ni en la conclusión.
- **El cambio en el diseño:** que cada persona pruebe las tres versiones por separado, sin ver ni oír a las demás (por ejemplo, en cabinas o en sesiones individuales), y anote su respuesta en privado.

Lo que tienen en común las cuatro preguntas

En las cuatro, los datos se ven bien: las frecuencias alcanzan, la prueba corre y el resultado es significativo. Lo que falla no está en los números, sino en **cómo se recogieron**: personas ligadas de a pares, grupos que trabajan juntos, alguien que aporta varias observaciones, o gente que se influye mutuamente. Por eso la independencia no se verifica con una frase (“la muestra es aleatoria”), sino leyendo con cuidado cómo se obtuvo cada dato.