Procedimientos ANOVA de una vía (actualizado el 08/11/2026 12:12)

Ejemplo de solución ejercicio práctico N°5

Conversación con la IA: https://gemini.google.com/share/d/1mFL6IW3L7MU09o_7LIPhKIHVjeKhj3D6?usp=sharing (https://gemini.google.com/share/d/1mFL6IW3L7MU09o_7LIPhKIHVjeKhj3D6?usp=sharing)

Este ejemplo resuelve dos preguntas con los datos del ejercicio, como se pide a los equipos: una con muestras independientes y otra con muestras correlacionadas. Para cada una elegimos, antes de mirar los resultados, el procedimiento ómnibus y el *post hoc* que corresponden a lo que interesa saber; formulamos las hipótesis, verificamos las condiciones, aplicamos las pruebas en R, comparamos con todos los pares corregidos con Holm y respondemos la pregunta. Antes de las preguntas va la discusión con la IA, que en el ejercicio se hacía en el avance 1.

Preparación

Comencemos cargando los paquetes que usaremos, leyendo los datos y fijando el nivel de significación de todas las preguntas.

```
# Cargar los paquetes
library(DescTools)
library(dplyr)
library(ggpubr)
library(rstatix)
library(tidyr)

# Leer los datos, que vienen separados por punto y coma
datos <- read.csv2("EP05 Datos.csv")

# Fijar el nivel de significación
alfa <- 0.05
```

La discusión con la IA

Comparamos cinco grupos correlacionados (las mismas unidades medidas en cinco condiciones). Es un estudio exploratorio: nos interesa identificar qué pares merecen un estudio más detallado, en el que se descartarán los falsos positivos. Se cumplen las condiciones, así que tras la prueba ómnibus elegimos pruebas t pareadas con la corrección de Benjamini y Hochberg. Defiende que debimos usar la corrección de Holm.

Es la elección de la pregunta 2, contada en términos generales, sin el enunciado ni los datos. Lo primero que pasó es que Gemini no hizo lo que le pedimos: en vez de defender la corrección de Holm, nos dio la razón. Tuvimos que insistirle en que asumiera el papel de quien la defiende, y recién ahí nos dio cuatro argumentos. Vale la pena notarlo: una IA tiende a estar de acuerdo con quien le pregunta, y para ponerla a prueba hay que pedirle explícitamente que no lo esté.

El primer argumento es que la corrección de Benjamini y Hochberg se pensó para estudios con miles de comparaciones, y que con solo 10, un único falso positivo puede ser la mitad o más de los pares que encontramos. No estamos de acuerdo. La corrección sirve para cualquier número de comparaciones: lo que asegura es que, **en promedio**, la proporción de pares encontrados que son falsos no supere el nivel que fijamos. Que en un estudio en particular esa proporción salga alta no la contradice, igual que un α de 0,05 no impide que una prueba en particular se equivoque.

El segundo argumento es que cada falso positivo que pasa a la etapa siguiente cuesta tiempo y dinero, porque hay que estudiarlo para descubrir que no existe. Este argumento es atendible. Pero dejar fuera una diferencia real también cuesta, y en una exploración cuesta más: un par que no pasa el filtro no se vuelve a mirar. Como el estudio siguiente va a descartar los falsos positivos, preferimos equivocarnos por incluir pares de más.

El tercero es que Holm no es tan estricto como parece, porque encuentra más diferencias que Bonferroni. Es cierto, pero sigue controlando lo mismo: que la probabilidad de cometer al menos un falso positivo entre las 10 comparaciones no supere α. Eso lo necesita un estudio que quiere confirmar diferencias, no uno que busca candidatos.

El cuarto es que las 10 comparaciones están relacionadas entre sí, porque usan los mismos días y cada estación aparece en cuatro pares, y que Holm funciona igual con comparaciones relacionadas. Aquí la IA tiene razón, y es su mejor argumento: Benjamini y Hochberg solo está garantizado con algunos tipos de relación entre las pruebas. Por eso, en la pregunta 2 también miramos qué pares cambian con Holm (el ejercicio lo pide de todos modos): si las dos listas difieren, los pares que solo marca Benjamini y Hochberg son los más débiles.

Mantenemos la corrección de Benjamini y Hochberg, porque se ajusta a lo que busca el estudio. De la IA tomamos dos cuidados: comparar con Holm y no presentar los pares encontrados como diferencias confirmadas.

Pregunta 1 · Muestras independientes

En la estación Parque O'Higgins, ¿la concentración diaria promedio de MP2,5 fue la misma en los inviernos de 2018, 2020, 2022 y 2025? En particular, interesa saber si el invierno de 2020, el de las cuarentenas por la pandemia, se diferenció del promedio de los demás inviernos.

El diseño y los procedimientos

Cada invierno aporta días distintos, elegidos al azar dentro de ese invierno, así que los cuatro grupos son **muestras independientes**. Queremos comparar cuatro medias, así que el procedimiento ómnibus es el ANOVA de una vía para muestras independientes.

Lo que interesa no es cada par de inviernos, sino una comparación en particular: el invierno de 2020 contra el **promedio** de los otros tres. Esa comparación no es un par, sino un **contraste**, con coeficientes 1 para 2020 y $-1/3$ para cada uno de los otros, que suman cero. El procedimiento *post hoc* que permite probar contrastes es el de **Scheffé**. Lo decidimos ahora, antes de mirar los resultados, porque es lo que pregunta el estudio.

Filtramos los datos y comprobamos que coinciden con los del enunciado.

```
# Filtrar los inviernos de la estación y dejar el invierno como factor
datos_1 <- datos |>
  filter(estacion == "Parque O'Higgins", invierno %in% c(2018, 2020, 2022, 2025)) |>
  mutate(invierno = factor(invierno))

# Calcular el tamaño, la media y la desviación estándar de cada invierno
resumen_1 <- datos_1 |> group_by(invierno) |>
  summarise(n = n(), media = mean(mp25), desv_est = sd(mp25))
print(resumen_1)
```

```
# A tibble: 4 × 4
  invierno     n media desv_est
  <fct>    <int> <dbl>    <dbl>
1 2018        22  43.7     13.3
2 2020        23  30.7     10.7
3 2022        23  43.7     14.5
4 2025        22  33.8     17.2
```

Quedan los cuatro inviernos de la pregunta, con 22 o 23 días cada uno. Las medias ya muestran dos parejas: los inviernos de 2018 y 2022 tuvieron una concentración diaria promedio de 43,68 y 43,74 µg/m³N, y los de 2020 y 2025, de 30,70 y 33,77 µg/m³N.

Las hipótesis

Como cada invierno aporta días distintos, las muestras son independientes, y las hipótesis se refieren a la media de cada invierno. Si μ_g es la concentración diaria promedio de MP2,5 que midió la estación Parque O'Higgins en el invierno g:

- H_0: en la estación Parque O'Higgins, la concentración diaria promedio de MP2,5 fue la misma en los inviernos de 2018, 2020, 2022 y 2025, $\mu_{2018} = \mu_{2020} = \mu_{2022} = \mu_{2025}$.
- H_A: en al menos uno de esos inviernos, la concentración diaria promedio de MP2,5 fue distinta de la de los demás, $\exists\, g, h \in \{2018, 2020, 2022, 2025\},\ g \neq h \mid \mu_g \neq \mu_h$.

Y para el contraste:

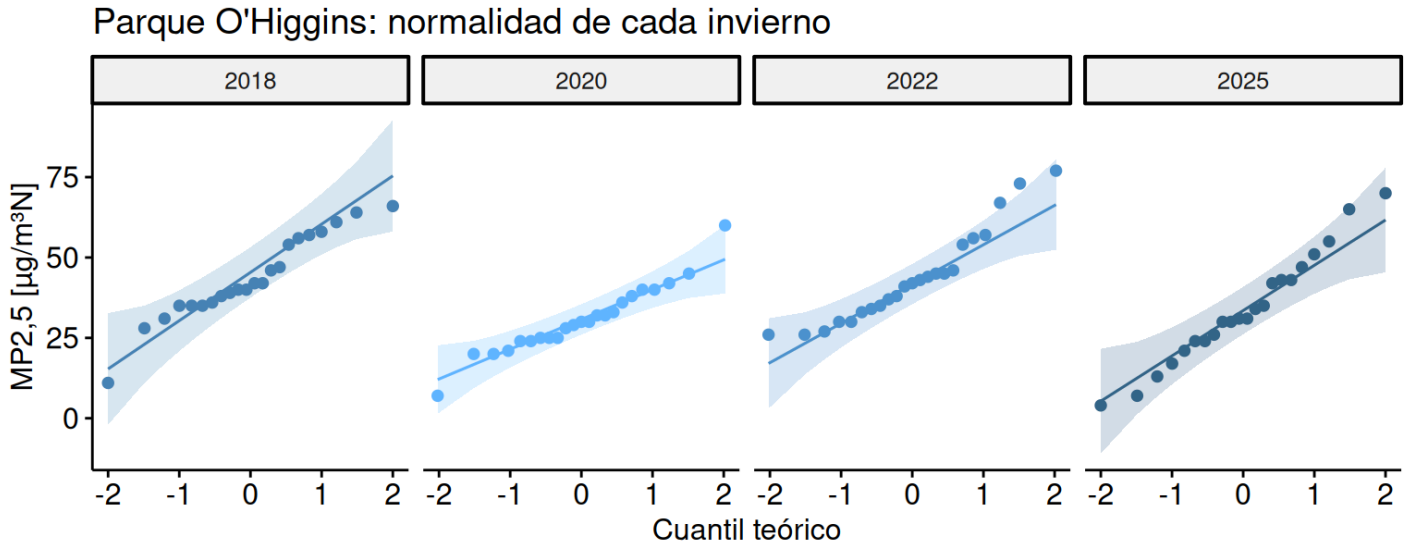
- H_0: la concentración diaria promedio del invierno de 2020 es igual al promedio de las de los otros tres inviernos, $\mu_{2020} - \frac{1}{3}(\mu_{2018} + \mu_{2022} + \mu_{2025}) = 0$.
- H_A: es distinta, $\mu_{2020} - \frac{1}{3}(\mu_{2018} + \mu_{2022} + \mu_{2025}) \neq 0$.

Las condiciones

- La concentración de MP2,5 se mide en una escala de razón (µg/m³N), así que tiene intervalos iguales.
- Las observaciones son independientes entre sí: los días se eligieron al azar, con al menos 4 días entre uno y otro para que la contaminación de un día no arrastre la del siguiente, y los inviernos no comparten días.
- La normalidad de cada grupo la revisamos con gráficos Q-Q y con la prueba de Shapiro-Wilk.
- La homocedasticidad, con la razón entre la mayor y la menor varianza, y con la prueba de Levene.

Comencemos con la normalidad de cada invierno.

```
# Graficar los cuantiles de cada invierno contra los de una normal
g_qq_1 <- ggqqplot(datos_1, x = "mp25", color = "invierno",
                   palette = c("steelblue", "steelblue1", "steelblue3", "steelblue4"),
                   title = "Parque O'Higgins: normalidad de cada invierno",
                   xlab = "Cuantil teórico", ylab = "MP2,5 [µg/m³N]")
g_qq_1 <- g_qq_1 + facet_wrap(~ invierno, nrow = 1) + rremove("legend")
print(g_qq_1)
```




```
# Aplicar la prueba de Shapiro-Wilk a cada invierno
print(datos_1 |> group_by(invierno) |> shapiro_test(mp25))
```

```
# A tibble: 4 × 4
  invierno variable statistic      p
  <fct>    <chr>        <dbl>  <dbl>
1 2018     mp25         0.954 0.372
2 2020     mp25         0.957 0.404
3 2022     mp25         0.915 0.0513
4 2025     mp25         0.978 0.886
```

Los puntos siguen la recta en los cuatro inviernos, con algo de curvatura en 2022, cuyo valor p (0,051) queda apenas sobre 0,05. Con grupos de 22 o 23 días, de tamaños casi iguales, ANOVA es robusto a una desviación así de moderada, pero de todas formas usaremos un nivel de significación más exigente, $\alpha = 0{,}025$, para protegernos más de un falso positivo.

```
# Fijar un nivel de significación más exigente para esta pregunta, por la duda sobre la normalidad
alfa_1 <- 0.025
```

Ahora comparamos las varianzas de los cuatro inviernos.

```
# Calcular la razón entre la mayor y la menor varianza
varianzas_1 <- resumen_1$desv_est^2
cat("Razón entre la mayor y la menor varianza:", coma(max(varianzas_1) / min(varianzas_
1), 2), "\n\n")

# Aplicar la prueba de Levene
print(datos_1 |> levene_test(mp25 ~ invierno))
```

```
Razón entre la mayor y la menor varianza: 2,57

# A tibble: 1 × 4
    df1   df2 statistic     p
  <int> <int>     <dbl> <dbl>
1     3    86      1.27 0.290
```

La mayor varianza es 2,57 veces la menor, más que el 1,5 que usamos como regla, así que hay razones para dudar de la homocedasticidad, aunque la prueba de Levene no la rechaza. Con tamaños casi iguales, ANOVA también es robusto a una desviación moderada como esta; además del nivel de significación más exigente que ya fijamos, comprobaremos la prueba ómnibus con el ANOVA de Welch, que no supone varianzas iguales.

La prueba ómnibus

Aplicamos el procedimiento ANOVA para muestras independientes con `anova_test()`.

```
# Aplicar el procedimiento ANOVA para muestras independientes
anova_1 <- datos_1 |> anova_test(mp25 ~ invierno, detailed = TRUE)
print(anova_1)
```

```
ANOVA Table (type II tests)

    Effect      SSn      SSd DFn DFd     F     p p<.05   ges
1 invierno 3087.882 17081.94   3  86 5.182 0.002     * 0.153
```

Con $F(3, 86) = 5{,}18$ y $p = 0{,}002$, menor que $\alpha = 0{,}025$, rechazamos la hipótesis nula: en al menos un invierno la concentración diaria promedio fue distinta.

Lo comprobamos con el ANOVA de Welch, con `welch_anova_test()`.

```
# Aplicar el ANOVA de Welch, que no supone varianzas iguales
welch_1 <- datos_1 |> welch_anova_test(mp25 ~ invierno)
print(welch_1)
```

```
# A tibble: 1 × 7
  .y.       n statistic   DFn   DFd     p method
* <chr> <int>     <dbl> <dbl> <dbl> <dbl> <chr>
1 mp25     90      6.23     3  46.9 0.001 Welch ANOVA
```

El ANOVA de Welch llega a la misma conclusión ($F(3; 46{,}9) = 6{,}23$; $p = 0{,}001$), así que la duda sobre las varianzas no cambia la decisión. El procedimiento *post hoc* corresponde.

Las condiciones del *post hoc*

Antes de aplicarlo, verificamos que se cumplan las condiciones de cada procedimiento *post hoc*. La prueba de Scheffé supone, como el ANOVA clásico, que los grupos son normales y tienen varianzas iguales. Con la duda que vimos sobre las varianzas (la razón superó 1,5, aunque Levene no rechazó), su resultado se lee con esa reserva. Las pruebas t de cada par, en cambio, no necesitan varianzas iguales si usamos la de Welch, que calcula cada prueba solo con las varianzas de los dos grupos que compara, así que los pares los comparamos con pruebas t de Welch (`var.equal = FALSE`) y el ajuste de Holm.

El procedimiento *post hoc*: Scheffé

Definimos el contraste que fijamos al comienzo, con sus coeficientes, y le aplicamos la prueba de Scheffé con `ScheffeTest()` , del paquete DescTools.

```
# Definir el contraste: 2020 contra el promedio de 2018, 2022 y 2025
contraste <- matrix(c(-1/3, 1, -1/3, -1/3), ncol = 1,
                    dimnames = list(levels(datos_1$invierno), "2020 vs. resto"))

# Aplicar la prueba de Scheffé al contraste elegido de antemano
aov_1 <- aov(mp25 ~ invierno, data = datos_1)
scheffe_1 <- ScheffeTest(aov_1, which = "invierno", contrasts = contraste,
                         conf.level = 1 - alfa_1)
print(scheffe_1)
p_scheffe <- scheffe_1$invierno[1, "pval"]
```

```
  Posthoc multiple comparisons of means: Scheffe Test
    97.5% family-wise confidence level

$invierno
                         diff    lwr.ci    upr.ci   pval
2020-2018,2022,2025 -9.70224 -20.37389 0.9694095 0.0504 .

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El invierno de 2020 tuvo, en promedio, 9,70 µg/m³N menos que el promedio de los otros tres, pero el valor p del contraste es 0,0504, mayor que 0,025, y el intervalo de confianza incluye el cero. Con el nivel de significación fijado, no podemos concluir que el invierno de 2020 se haya diferenciado del promedio de los demás, con la reserva que ya dijimos sobre las varianzas.

Todos los pares, con Holm

Como pide el ejercicio, comparamos además todos los pares de inviernos con pruebas t de Welch, con la corrección de Holm.

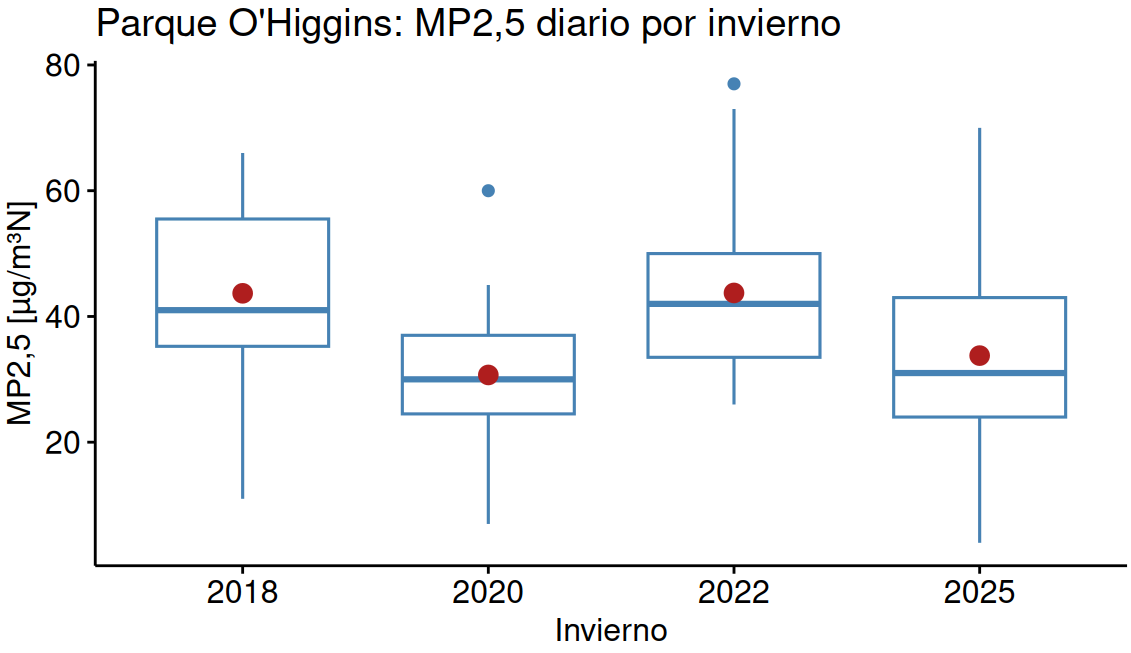
```
# Comparar todos los pares de inviernos con pruebas t de Welch, ajustando con Holm
pares_1 <- datos_1 |>
  pairwise_t_test(mp25 ~ invierno, pool.sd = FALSE, var.equal = FALSE,
                  p.adjust.method = "holm") |>
  dplyr::select(group1, group2, p, p.adj)
print(pares_1)
```

```
# A tibble: 6 × 4
  group1 group2        p   p.adj
  <chr>  <chr>     <dbl>   <dbl>
1 2018   2020   0.000876 0.00525
2 2018   2022   0.989    0.989
3 2018   2025   0.0389   0.156
4 2020   2022   0.00124  0.00621
5 2020   2025   0.479    0.958
6 2022   2025   0.0421   0.156
```

Las comparaciones por pares cuentan algo que el contraste no muestra: el invierno de 2020 tuvo menos MP2,5 que los de 2018 y 2022 (con *p* ajustado 0,005 y 0,006), pero no se distingue del de 2025, que también tuvo menos que 2018 y 2022, aunque sin llegar a ser significativo con Holm (*p* ajustado 0,156 en los dos pares). El de 2025 se parece al de 2020 y, al entrar en “los demás”, **diluye el contraste**: el promedio de los otros tres baja, y la diferencia con 2020 se achica.

Un diagrama de cajas, con la media de cada invierno marcada en rojo, permite verlo.

```
# Graficar la concentración de cada invierno, con su media
g_cajas_1 <- ggboxplot(datos_1, x = "invierno", y = "mp25", color = "steelblue",
                       add = "mean", add.params = list(color = "firebrick"),
                       title = "Parque O'Higgins: MP2,5 diario por invierno",
                       xlab = "Invierno", ylab = "MP2,5 [µg/m³N]")
print(g_cajas_1)
```



Las medias de 2020 y 2025 quedan bajo las de 2018 y 2022, que están casi a la misma altura: al promediar 2025 con 2018 y 2022, el grupo de “los demás” queda más cerca de 2020.

Como Scheffé controla el error para todos los contrastes posibles, podemos probar también uno que sugiere el gráfico: 2018 y 2022 contra 2020 y 2025.

```
# Definir el contraste sugerido por el gráfico: 2018 y 2022 contra 2020 y 2025
contraste_2 <- matrix(c(1/2, -1/2, 1/2, -1/2), ncol = 1,
                      dimnames = list(levels(datos_1$invierno), "2018 y 2022 vs. 2020 y
2025"))

# Aplicar la prueba de Scheffé al contraste elegido después de ver los datos
scheffe_2 <- ScheffeTest(aov_1, which = "invierno", contrasts = contraste_2,
                         conf.level = 1 - alfa_1)
print(scheffe_2)
```

```
  Posthoc multiple comparisons of means: Scheffe Test
    97.5% family-wise confidence level

$invierno
                         diff   lwr.ci   upr.ci   pval
2018,2022-2020,2025 11.47628 2.165136 20.78743 0.0031 **

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Los inviernos de 2018 y 2022 tuvieron, en promedio, 11,48 µg/m³N más que los de 2020 y 2025, con un valor p de 0,0031. Pero esto responde otra pregunta, no la del estudio, que era si 2020 se diferenció del promedio de los otros tres.

Con un nivel de significación de 0,025, en la estación Parque O’Higgins la concentración diaria promedio de MP2,5 no fue la misma en los inviernos de 2018, 2020, 2022 y 2025 ($F(3, 86) = 5{,}18$; $p = 0{,}002$). Sin embargo, no hay evidencia suficiente para afirmar que el invierno de 2020, el de las cuarentenas, se haya diferenciado del promedio de los otros tres (Scheffé: 9,70 µg/m³N menos que el promedio de los otros tres; $p = 0{,}0504$). Las comparaciones por pares con Holm muestran que el de 2020 tuvo menos MP2,5 que los de 2018 y 2022, pero no que el de 2025.

Pregunta 2 · Muestras correlacionadas

En el invierno de 2022, ¿la concentración diaria promedio de MP2,5 fue la misma en las estaciones Cerro Navia, La Florida, Parque O’Higgins, Pudahuel y Puente Alto? Es un primer análisis exploratorio: interesa identificar qué pares de estaciones merecen un estudio más detallado, en el que se descartarán los falsos positivos.

El diseño y los procedimientos

Las cinco estaciones miden **los mismos días**, así que las cinco muestras son **correlacionadas**: un día con aire estancado sube la concentración en todas las estaciones a la vez. El día es el caso, y cada estación es una condición en que se lo mide. El procedimiento ómnibus es el ANOVA de una vía para muestras correlacionadas.

Con cinco estaciones hay 10 pares, y la pregunta pide explorarlos para elegir cuáles estudiar después. Como un falso positivo se descartará en el estudio siguiente, lo que conviene controlar no es la probabilidad de cometer al menos uno, sino la proporción esperada de descubrimientos falsos: el *post hoc* es el de pruebas t pareadas con la corrección de **Benjamini y Hochberg**. Es la elección que discutimos con la IA.

Filtramos los datos y comprobamos que coinciden con los del enunciado.

```
# Filtrar las estaciones del invierno y dejar el día y la estación como factores
estaciones <- c("Cerro Navia", "La Florida", "Parque O'Higgins", "Pudahuel", "Puente Alt
o")
datos_2 <- datos |>
  filter(invierno == 2022, estacion %in% estaciones) |>
  mutate(fecha = factor(fecha), estacion = factor(estacion))

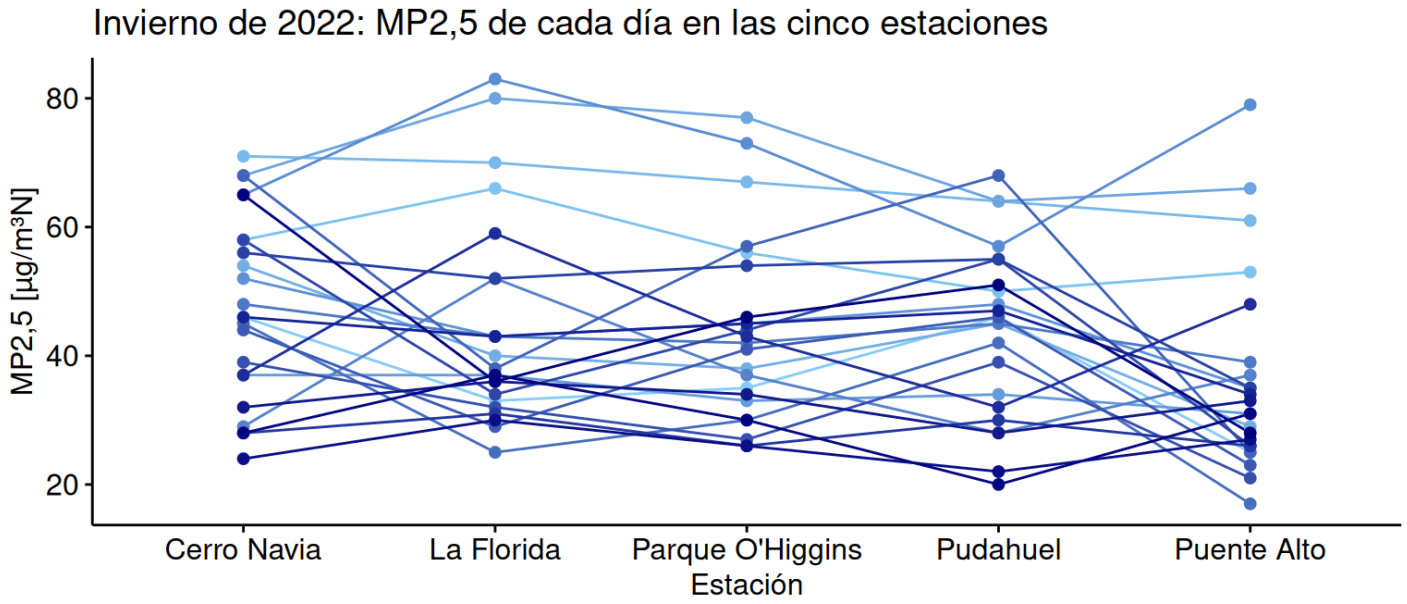
# Calcular el tamaño, la media y la desviación estándar de cada estación
resumen_2 <- datos_2 |> group_by(estacion) |>
  summarise(n = n(), media = mean(mp25), desv_est = sd(mp25))
print(resumen_2)
```

```
# A tibble: 5 × 4
  estacion             n media desv_est
  <fct>            <int> <dbl>    <dbl>
1 Cerro Navia         23  47.7     14.4
2 La Florida          23  44.7     16.4
3 Parque O'Higgins    23  43.7     14.5
4 Pudahuel            23  44.2     13.4
5 Puente Alto         23  36.0     15.5
```

Quedan las cinco estaciones de la pregunta, cada una con 23 días: como dice el enunciado, todas tienen dato en los mismos días. Cerro Navia y Pudahuel tuvieron las concentraciones diarias promedio más altas (47,7 y 44,2 µg/m³N), y Puente Alto, la más baja (36,0 µg/m³N). Las desviaciones estándar, de 13,4 a 16,4 µg/m³N, muestran que la concentración cambia mucho de un día a otro.

Para ver cómo se relacionan las cinco mediciones de un mismo día, unimos con una línea las de cada día.

```
# Graficar cada día como una línea que une sus cinco mediciones, con un tono de azul por
día
azules <- colorRampPalette(c("lightskyblue", "navy"))(nlevels(datos_2$fecha))
g_dias_2 <- ggline(datos_2, x = "estacion", y = "mp25", group = "fecha",
                   color = "fecha", palette = azules, legend = "none",
                   title = "Invierno de 2022: MP2,5 de cada día en las cinco estacione
s",
                   xlab = "Estación", ylab = "MP2,5 [µg/m³N]")
print(g_dias_2)
```



El gráfico muestra por qué el día importa: la diferencia entre un día limpio y uno contaminado es mucho mayor que la diferencia entre estaciones, así que comparar las estaciones día a día descuenta una variación que, de otro modo, taparía las diferencias. También se ve que la mayoría de las líneas baja al llegar a Puente Alto.

Las hipótesis

Como las cinco estaciones miden los mismos días, las muestras son correlacionadas, y las hipótesis se refieren a las diferencias entre lo que miden dos estaciones un mismo día. Si d_{X-Y} es la diferencia entre las concentraciones diarias de MP2,5 que miden las estaciones X e Y un mismo día del invierno de 2022, y $\mu_{d_{X-Y}}$ es la media de esas diferencias:

- H_0: en el invierno de 2022, en promedio, no hubo diferencias entre las concentraciones diarias de MP2,5 que midieron dos de las cinco estaciones un mismo día; es decir, $\mu_{d_{X-Y}} = 0$ para todo par X, Y de estaciones.
- H_A: la media de las diferencias entre las concentraciones diarias de MP2,5 que midieron dos estaciones un mismo día fue distinta de cero para al menos un par, $\exists\, X, Y,\ X \neq Y \mid \mu_{d_{X-Y}} \neq 0$.

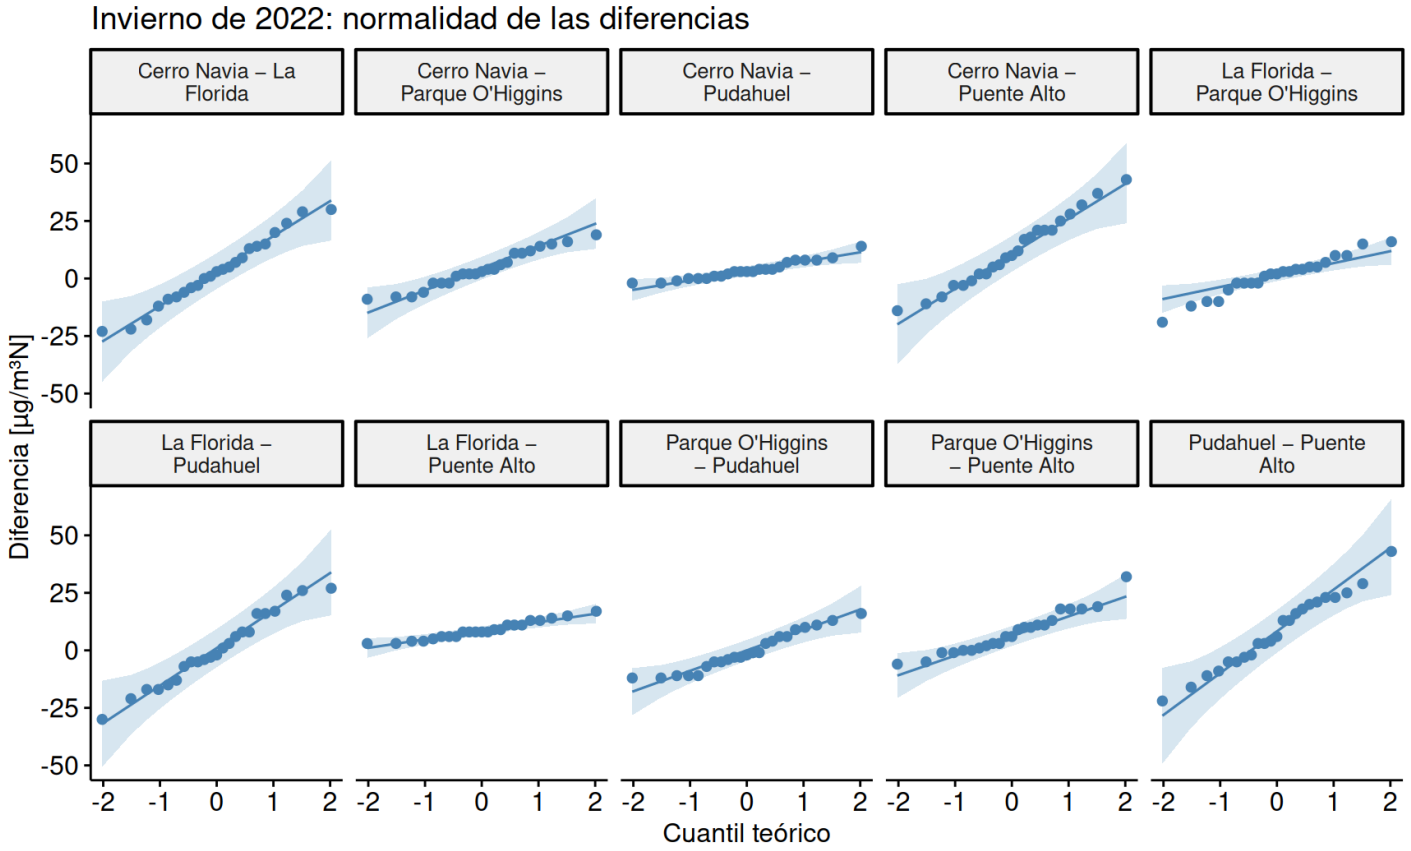
Las condiciones

- La escala es de razón, como en la pregunta 1.
- Los días son independientes entre sí, por cómo se eligieron, aunque las cinco mediciones de un mismo día no lo son: eso es lo que el diseño correlacionado tiene en cuenta.
- La normalidad, en este diseño, es la de las **diferencias** entre cada par de estaciones.
- La esfericidad la revisan la prueba de Mauchly y la estimación $\hat{\epsilon}$ de Greenhouse-Geisser, que entrega `anova_test()`.

Calculamos la diferencia de cada día entre cada par de estaciones y revisamos su normalidad.

```
# Calcular la diferencia de cada día entre cada par de estaciones
anchos_2 <- datos_2 |> dplyr::select(fecha, estacion, mp25) |>
  pivot_wider(names_from = estacion, values_from = mp25)
pares_est <- combn(estaciones, 2, simplify = FALSE)
diferencias_2 <- bind_rows(lapply(pares_est, function(par) data.frame(
  par = paste(par, collapse = " – "),
  diferencia = anchos_2[[par[1]]] - anchos_2[[par[2]]])))

# Graficar los cuantiles de cada diferencia contra los de una normal
g_qq_2 <- ggqqplot(diferencias_2, x = "diferencia", color = "steelblue",
                   title = "Invierno de 2022: normalidad de las diferencias",
                   xlab = "Cuantil teórico", ylab = "Diferencia [µg/m³N]")
g_qq_2 <- g_qq_2 + facet_wrap(~ par, nrow = 2, labeller = label_wrap_gen(18))
print(g_qq_2)
```




```
# Aplicar la prueba de Shapiro-Wilk a cada diferencia
normalidad_2 <- diferencias_2 |> group_by(par) |> shapiro_test(diferencia)
print(normalidad_2, n = Inf)
```

```
# A tibble: 10 × 4
   par                           variable   statistic     p
   <chr>                         <chr>          <dbl> <dbl>
 1 Cerro Navia - La Florida      diferencia     0.977 0.858
 2 Cerro Navia - Parque O'Higgins diferencia    0.961 0.486
 3 Cerro Navia - Pudahuel        diferencia     0.941 0.185
 4 Cerro Navia - Puente Alto     diferencia     0.979 0.888
 5 La Florida - Parque O'Higgins  diferencia    0.967 0.618
 6 La Florida - Pudahuel         diferencia     0.972 0.746
 7 La Florida - Puente Alto      diferencia     0.957 0.405
 8 Parque O'Higgins - Pudahuel   diferencia     0.943 0.203
 9 Parque O'Higgins - Puente Alto diferencia    0.945 0.229
10 Pudahuel - Puente Alto        diferencia     0.982 0.933
```

En ninguna de las 10 diferencias la prueba de Shapiro-Wilk rechaza la normalidad (el menor valor p es 0,185), y en los gráficos Q-Q los puntos siguen la recta, salvo alguno en los extremos, así que no tenemos razones para dudar de esta condición.

La prueba ómnibus

Aplicamos el procedimiento ANOVA para muestras correlacionadas con `anova_test()`, con el día como caso (`wid`) y la estación como condición (`within`).

```
# Aplicar el procedimiento ANOVA para muestras correlacionadas
anova_2 <- datos_2 |> anova_test(dv = mp25, wid = fecha, within = estacion, detailed = T
RUE)
print(anova_2)
gg <- anova_2$`Sphericity Corrections`
```

```
ANOVA Table (type III tests)

$ANOVA
       Effect DFn DFd        SSn       SSd       F        p p<.05   ges
1 (Intercept)   1  22 215482.470 18624.730 254.533 1.41e-13     * 0.899
2    estacion   4  88   1733.965  5686.835   6.708 9.26e-05     * 0.067

$`Mauchly's Test for Sphericity`
    Effect     W        p p<.05
1 estacion 0.006 6.13e-18     *

$`Sphericity Corrections`
    Effect   GGe      DF[GG] p[GG] p[GG]<.05   HFe      DF[HF] p[HF] p[HF]<.05
1 estacion 0.303 1.21, 26.66 0.011         * 0.311 1.24, 27.38 0.011         *
```

La prueba de Mauchly rechaza la esfericidad, y $\hat{\epsilon}_{GG} = 0{,}303$ está muy lejos de 1 (con cinco estaciones, el mínimo posible es $1/4 = 0{,}25$). Como $\hat{\epsilon}_{GG} < 0{,}60$, usamos la corrección de Greenhouse-Geisser.

Con $F(1{,}21; 26{,}66) = 6{,}71$ y $p = 0{,}011$, con la corrección de Greenhouse-Geisser, rechazamos la hipótesis nula: la media de las diferencias entre lo que miden dos estaciones un mismo día es distinta de cero para al menos un par. Como las diferencias no muestran problemas de normalidad, la corrección basta, y mantenemos $\alpha = 0{,}05$.

Esa normalidad de las diferencias es también la condición de las pruebas t pareadas del procedimiento *post hoc*, así que lo que revisamos para la prueba ómnibus vale para los pares. El procedimiento *post hoc* corresponde.

El procedimiento *post hoc*: Benjamini y Hochberg, y todos los pares con Holm

Comparamos los 10 pares de estaciones con pruebas t pareadas, con la corrección de Benjamini y Hochberg y, como pide el ejercicio, también con la de Holm.

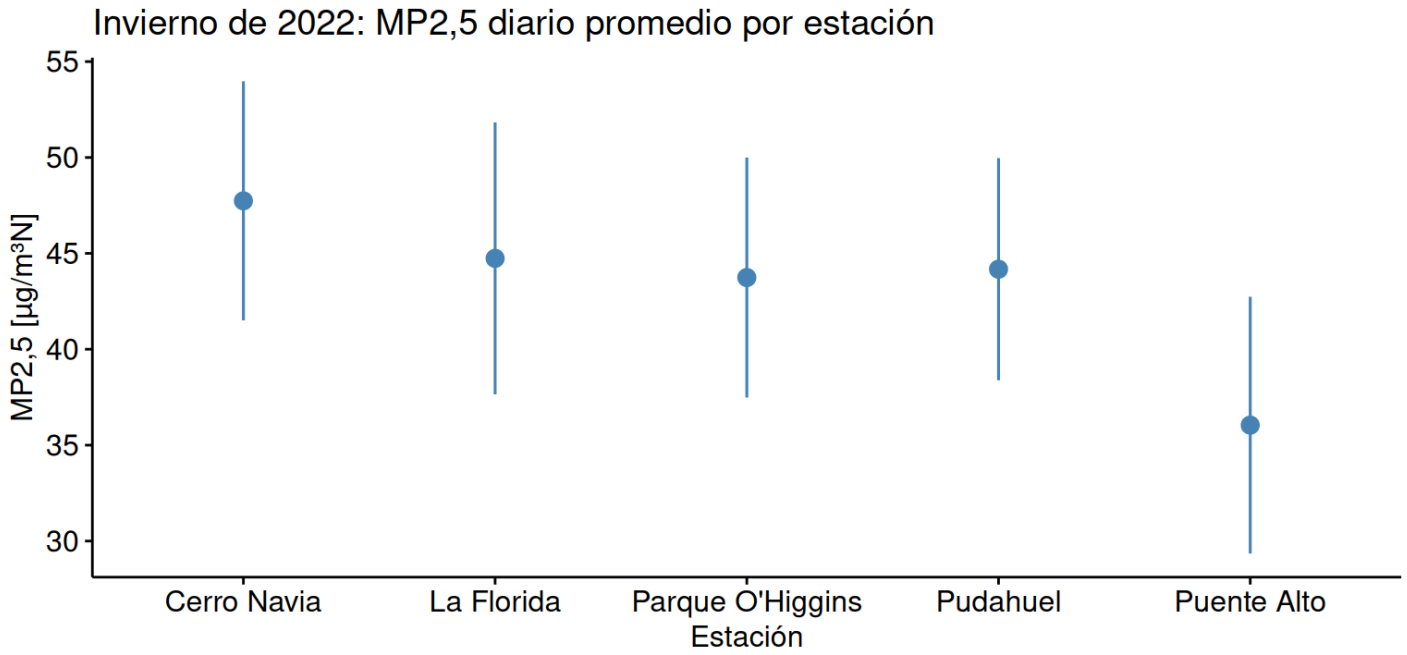
```
# Comparar los pares de estaciones con pruebas t pareadas, ajustando con
# Benjamini y Hochberg y, para comparar, con Holm.
pares_2 <- datos_2 |>
  pairwise_t_test(mp25 ~ estacion, paired = TRUE, p.adjust.method = "none") |>
  mutate(p.BH = p.adjust(p, method = "BH"), p.Holm = p.adjust(p, method = "holm")) |>
  dplyr::select(group1, group2, p, p.BH, p.Holm)
print(pares_2)
```

```
# A tibble: 10 × 5
   group1           group2                  p          p.BH        p.Holm
   <chr>            <chr>               <dbl>         <dbl>         <dbl>
 1 Cerro Navia      La Florida       3.49e- 1 0.498         1
 2 Cerro Navia      Parque O'Higgins 2.75e- 2 0.0458        0.144
 3 Cerro Navia      Pudahuel         2.98e- 4 0.00149       0.00268
 4 Cerro Navia      Puente Alto      1.46e- 3 0.00365       0.0102
 5 La Florida       Parque O'Higgins 5.75e- 1 0.719         1
 6 La Florida       Pudahuel         8.64e- 1 0.864         1
 7 La Florida       Puente Alto      3.74e-10 0.000000003374 0.000000003374
 8 Parque O'Higgins Pudahuel         8.10e- 1 0.864         1
 9 Parque O'Higgins Puente Alto      5.60e- 4 0.00187       0.00448
10 Pudahuel         Puente Alto      2.40e- 2 0.0458        0.144
```

Con Benjamini y Hochberg, 6 de los 10 pares quedan marcados para el estudio siguiente; con Holm, 4. Los 4 pares de Holm están también en la lista de Benjamini y Hochberg, que agrega Cerro Navia–Parque O'Higgins y Pudahuel–Puente Alto, ambos con un valor p ajustado de 0,046 con Benjamini y Hochberg y de 0,144 con Holm. Son los candidatos más débiles de la lista: si la dependencia entre las comparaciones, el argumento más fuerte de la IA, hiciera fallar a Benjamini y Hochberg, serían los primeros en caer, y por eso son los primeros que el estudio siguiente debería revisar. Lo que sí cambia es cómo se lee: con Holm, los 4 pares serían diferencias con un riesgo controlado de que alguna sea falsa; con Benjamini y Hochberg, los 6 son candidatos, y se espera que una pequeña proporción de ellos no resista el estudio siguiente.

Por último, graficamos la media de cada estación con su intervalo de confianza.

```
# Graficar la media de cada estación con su intervalo de confianza
g_medias_2 <- ggerrorplot(datos_2, x = "estacion", y = "mp25", desc_stat = "mean_ci",
                          color = "steelblue",
                          title = "Invierno de 2022: MP2,5 diario promedio por estació
n",
                          xlab = "Estación", ylab = "MP2,5 [µg/m³N]")
print(g_medias_2)
```



Los intervalos del gráfico se traslapan mucho porque cada uno incluye la variación entre días, que en el diseño correlacionado se descuenta: por eso las pruebas pareadas encuentran diferencias que el gráfico no deja ver.

Con un nivel de significación de 0,05, en el invierno de 2022, en promedio, hubo diferencias entre las concentraciones diarias de MP2,5 que midieron al menos dos de las cinco estaciones un mismo día ($F(1{,}21; 26{,}66) = 6{,}71$; $p = 0{,}011$, con la corrección de Greenhouse-Geisser). Como primer análisis exploratorio, 6 de los 10 pares de estaciones merecen un estudio más detallado (pruebas t pareadas con la corrección de Benjamini y Hochberg): Puente Alto con cada una de las otras cuatro, y Cerro Navia con Parque O'Higgins y con Pudahuel. Son candidatos, no diferencias confirmadas.

Lo que tienen en común

En las dos preguntas la prueba ómnibus rechazó, pero eso no decía qué comparación explicaba la diferencia. En la primera, la comparación que interesaba no resultó significativa, y los pares mostraron por qué: lo que la pregunta agrupaba como "los demás" no era un grupo parejo. En la segunda, la elección entre Benjamini y Hochberg y Holm cambió dos pares, los más débiles, y cambió cómo se lee cada uno de ellos. En las dos, la elección del procedimiento se hizo antes de ver los resultados, y es lo que permite que la respuesta no dependa de lo que los datos mostraron.

La versión de R

Dejamos registrada la versión de R con que se hizo el análisis.

```
# Mostrar la versión de R con que se hizo el análisis
cat(R.version.string, "\n")
```

```
R version 4.6.2 (2026-10-29)
```